

Теория вероятности и математическая статистика, 2 курс, 2 семестр

@defunator

3 июня 2020 г.

Содержание

1	Сходимости случайных величин	2
2	Характеристические функции	6
3	Неравенство типа Хефдинга-Чернова	9
4	Теоремы непрерывности	11
5	Многомерная характеристическая функция и ЦПТ	14
6	Многомерное нормальное распределение	17
7	Условные математические ожидания: дискретный случай	20
8	Условные математические ожидания: общий случай	23
9	Оценки параметров и их свойства	26
10	Метод моментов	28
11	Информация Фишера и неравенство Рао-Крамера	29
12	Метод максимального правдоподобия	32
13	Доверительные интервалы	36
14	Проверка гипотез. Критерий Неймана-Пирсона	39
15	χ^2 -критерий Пирсона	42
16	Эмпирическая функция распределения и теорема Гливенко-Кантелли	43

1 Сходимости случайных величин

Определение 1. Последовательность случайных величин ξ_n сходится к случайной величине ξ :

1. Почти наверное ($\xi_n \xrightarrow{\text{п.н.}} \xi$), если

$$P\left(\lim_{n \rightarrow \infty} \xi_n = \xi\right) = 1$$

2. По вероятности ($\xi_n \xrightarrow{P} \xi$), если

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\xi_n - \xi| \geq \varepsilon) = 0$$

3. По распределению ($\xi_n \xrightarrow{d} \xi$), если

$$\lim_{n \rightarrow \infty} F_{\xi_n}(x) = F_{\xi}(x)$$

для любых x , в которых непрерывна F_{ξ}

Теорема 1. (Эквивалентное определение сходимости по распределению) $\xi_n \xrightarrow{d} \xi \Leftrightarrow \forall g$ — непрерывна и ограничена на \mathbb{R} верно $\lim_{n \rightarrow \infty} \mathbb{E}g(\xi_n) = \mathbb{E}g(\xi)$

Доказательство. \Rightarrow

Пусть t — точка непрерывности $F_{\xi}(t)$. Заметим, что $F_{\xi}(t) = P(\xi \in (-\infty, t]) = \mathbb{E}\text{Ind}_{(-\infty, t]}(\xi)$.

В силу:

$$(1) \mathbb{E}\text{Ind}_{(a_i, b_i]}(\xi_n) = F_{\xi_n}(b_i) - F_{\xi_n}(a_i) \xrightarrow{n \rightarrow \infty} F_{\xi}(b_i) - F_{\xi}(a_i) = \mathbb{E}\text{Ind}_{(a_i, b_i]}(\xi)$$

(2) Линейность предела (с какими-то коэффициентами c_i)

Верна следующая сходимость:

$$\mathbb{E} \sum_{i=1}^N c_i \cdot \text{Ind}_{(a_i, b_i]}(\xi_n) \rightarrow \mathbb{E} \sum_{i=1}^N c_i \cdot \text{Ind}_{(a_i, b_i]}(\xi)$$

Теперь нам бы хотелось от непрерывной ограниченной функции на прямой перейти к функции на отрезке, а там мы уже сможем ее приблизить ступенчатой и воспользоваться предыдущим утверждением и все доказать. Мы знаем, что

$\forall \varepsilon > 0 \exists A: P(-A < \xi \leq A) > 1 - \varepsilon$ (потому что $P(\xi \in \mathbb{R}) = 1$). Тогда получаем:

$$F_{\xi_n}(A) - F_{\xi_n}(-A) \xrightarrow{n \rightarrow \infty} F_{\xi}(A) - F_{\xi}(-A) = P(-A < \xi \leq A) > 1 - \varepsilon$$

То есть для $\forall \varepsilon > 0 \exists N \forall n > N$ верно:

$$|(F_{\xi_n}(A) - F_{\xi_n}(-A)) - (F_{\xi}(A) - F_{\xi}(-A))| < \varepsilon$$

Комбинируя последние два утверждения, получаем для $\forall \varepsilon > 0 \exists A \exists N \forall n > N$:

$$F_{\xi_n}(A) - F_{\xi_n}(-A) > F_{\xi}(A) - F_{\xi}(-A) - \varepsilon > 1 - 2\varepsilon$$

Из чего следует $\forall \varepsilon > 0 \exists A \exists N \forall n > N$:

$$P(-A \leq \xi_n \leq A) \geq F_{\xi_n}(A) - F_{\xi_n}(-A) > 1 - \varepsilon$$

Теперь возьмем любую непрерывную ограниченную функцию g , приблизим ее на отрезке $[-A, A]$ ступенчатой функцией g_{ε} , что $|g(x) - g_{\varepsilon}(x)| < \varepsilon$, а вне отрезка положим $g_{\varepsilon} = 0$. Имеем $\forall \varepsilon > 0 \exists A \forall n$:

$$|\mathbb{E}g(\xi_n) - \mathbb{E}g(\xi)| \leq |\mathbb{E}(1 - \text{Ind}_{[-A, A]}(\xi_n)) \cdot g(\xi_n) - \mathbb{E}(1 - \text{Ind}_{[-A, A]}(\xi)) \cdot g(\xi)| +$$

$$+ |\mathbb{E} \text{Ind}_{[-A, A]}(\xi_n) \cdot g(\xi_n) - \mathbb{E} \text{Ind}_{[-A, A]}(\xi) \cdot g(\xi)|$$

Ясно, что первый модуль $< C \cdot 2\varepsilon$ (из ограниченности $g \forall x_1, x_2: |g(x_1) - g(x_2)| < C$ и так как $P(|\xi| > A), P(|\xi_n| > A) < \varepsilon$). А во втором модуле g заменим на g_ε с погрешностью ε , то есть он $< 2\varepsilon + |\mathbb{E} \text{Ind}_{[-A, A]}(\xi_n) \cdot g_\varepsilon(\xi_n) - \mathbb{E} \text{Ind}_{[-A, A]}(\xi) \cdot g_\varepsilon(\xi)|$. А про оставшийся модуль мы уже знаем, что он сходится к 0, так как ступенчатая функция (то есть $< \varepsilon$ для $\forall n > N$). В итоге имеем: $|\mathbb{E} g(\xi_n) - \mathbb{E} g(\xi)| < \varepsilon$. То есть $\lim_{n \rightarrow \infty} \mathbb{E} g(\xi_n) = \mathbb{E} g(\xi)$

←

Пусть t — точка непрерывности $F_\xi(t)$. Мы знаем, что $F_\xi(t) = \mathbb{E} \text{Ind}_{(-\infty, t]}(\xi)$. Для $\forall \delta > 0$ определим функции:

$$g_{-\delta}(x) = \begin{cases} 1 & x < t - \delta \\ \frac{1}{\delta} \cdot (t - x) & t - \delta \leq x \leq t \\ 0 & t < x \end{cases}$$

$$g_{+\delta}(x) = \begin{cases} 1 & x < t \\ \frac{1}{\delta} \cdot (t - x) & t \leq x \leq t + \delta \\ 0 & t + \delta < x \end{cases}$$

Заметим, что $\forall x$:

$$\text{Ind}_{(-\infty, t-\delta]}(x) \leq g_{-\delta}(x) \leq \text{Ind}_{(-\infty, t]}(x) \leq g_{+\delta}(x) \leq \text{Ind}_{(\infty, t+\delta]}(x)$$

Взяв матожидания ($x = \xi_n$) от второго и третьего неравенств, получим:

$$\mathbb{E} g_{-\delta}(\xi_n) \leq F_{\xi_n}(t) \leq \mathbb{E} g_{+\delta}(\xi_n)$$

Теперь устремим $n \rightarrow \infty$:

$$\mathbb{E} g_{-\delta}(\xi) \leq \inf_{n \rightarrow \infty} \lim F_{\xi_n}(x) \leq \sup_{n \rightarrow \infty} \lim F_{\xi_n}(x) \leq \mathbb{E} g_{+\delta}(\xi)$$

Рассмотрим первое и последнее неравенство той цепочки ($x = \xi$ и возьмем то него матожидание), получим:

$$F_\xi(t - \delta) \leq \mathbb{E} g_{-\delta}(\xi) \leq \mathbb{E} g_{+\delta}(\xi) \leq F_\xi(t + \delta)$$

Теперь $\delta \rightarrow 0$:

$$F_\xi(t) = \mathbb{E} g_{-\delta}(\xi) = \inf_{n \rightarrow \infty} \lim F_{\xi_n}(t) = \sup_{n \rightarrow \infty} \lim F_{\xi_n}(t) = \mathbb{E} g_{+\delta}(\xi)$$

Получаем: $F_\xi(t) = \lim_{n \rightarrow \infty} F_{\xi_n}(t)$

■

Теорема 2. $\xi_n \xrightarrow{n.n.} \xi \Rightarrow \xi_n \xrightarrow{p} \xi$

Доказательство. Знаем $P\left(\lim_{n \rightarrow \infty} \xi_n = \xi\right) = 1$. Заметим вложенность следующих событий для $\forall \varepsilon >$

0: $\left\{\lim_{n \rightarrow \infty} \xi_n = \xi\right\} \Rightarrow \bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{|\xi_n - \xi| < \varepsilon\}$ (это по сути и есть определение предела, что для $\forall \varepsilon$, начиная с некоторого N выполняется условие). То есть:

$$1 = P\left(\lim_{n \rightarrow \infty} \xi_n = \xi\right) \leq P\left(\bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{|\xi_n - \xi| < \varepsilon\}\right) = 1$$

Так как последовательность множеств $A_N = \bigcap_{n=N}^{\infty} \{|\xi_n - \xi| < \varepsilon\}$ расширяющаяся ($A_N \subseteq A_{N+1}$), в объединении они дают событие вероятности 1, значит по теореме непрерывности $\lim_{N \rightarrow \infty} P(A_N) = 1$.

Теперь заметим: $P(A_N) \leq P(|\xi_N - \xi| < \varepsilon)$. То есть: $\lim_{N \rightarrow \infty} P(|\xi_N - \xi| < \varepsilon) = 1$. Или что то же самое: $\lim_{N \rightarrow \infty} (1 - P(|\xi_N - \xi| < \varepsilon)) = \lim_{N \rightarrow \infty} P(|\xi_N - \xi| \geq \varepsilon) = 0$ — определение сходимости по вероятности. ■

Теорема 3. (Теорема Лебега о мажорируемой сходимости) $\xi_n \xrightarrow{p} \xi$ и $|\xi_n|, |\xi| \leq \eta$ п. н. (где η — случайная величина, что $\mathbb{E}\eta < \infty$), то $\mathbb{E}\xi_n \rightarrow \mathbb{E}\xi$

Доказательство. Докажем теорему в частном случае, когда $\eta \equiv C$. $\forall \varepsilon > 0 \forall n$ $|\mathbb{E}\xi_n - \mathbb{E}\xi| \leq \mathbb{E}|\xi_n - \xi| = \mathbb{E}|\xi_n - \xi| \cdot \text{Ind}_{|\xi_n - \xi| \geq \varepsilon} + \mathbb{E}|\xi_n - \xi| \cdot \text{Ind}_{|\xi_n - \xi| < \varepsilon} \leq 2C \cdot P(|\xi_n - \xi| \geq \varepsilon) + \varepsilon \cdot 1$. Так как $\xi_n \xrightarrow{p} \xi$, то $\exists N \forall n > N: P(|\xi_n - \xi| \geq \varepsilon) < \varepsilon$. Тогда получаем: $|\mathbb{E}\xi_n - \mathbb{E}\xi| < 2C \cdot \varepsilon + \varepsilon$. То есть $\mathbb{E}\xi_n \rightarrow \mathbb{E}\xi$. ■

Предложение 1. $\xi_n \xrightarrow{p} \xi \Rightarrow$ для $\forall g$ — непрерывная, $g(\xi_n) \xrightarrow{p} g(\xi)$

Доказательство. Знаем для любой случайной величины $\forall \varepsilon > 0 \exists A: P\left(|\xi| > \frac{A}{2}\right) < \varepsilon$. $\exists N \forall n > N$:

$$P(|\xi_n| > A) \leq P(|\xi - \xi_n| + |\xi| > A) \leq P\left(|\xi - \xi_n| > \frac{A}{2} \vee |\xi| > \frac{A}{2}\right) \leq P\left(|\xi - \xi_n| > \frac{A}{2}\right) + P\left(|\xi| > \frac{A}{2}\right) < \varepsilon$$

. Теперь возьмем g , она равномерно непрерывна на $[-A, A]$:

$$\forall \varepsilon > 0 \exists \delta > 0: |x - y| < \delta \Rightarrow |g(x) - g(y)| < \varepsilon \quad \forall x, y \in [-A, A]$$

Докажем $g(\xi_n) \xrightarrow{p} g(\xi)$:

$$\begin{aligned} P(|g(\xi_n) - g(\xi)| \geq \varepsilon) &= P(|g(\xi_n) - g(\xi)| \geq \varepsilon \mid \xi_n, \xi \in [-A, A]) \cdot P(\xi_n, \xi \in [-A, A]) + \\ &+ P(|g(\xi_n) - g(\xi)| \geq \varepsilon \mid \xi_n, \xi \notin [-A, A]) \cdot P(\xi_n, \xi \notin [-A, A]) \end{aligned}$$

Посмотрев на определение равномерной непрерывности, заметим, что:

$$P(|g(\xi_n) - g(\xi)| \geq \varepsilon \mid \xi_n, \xi \in [-A, A]) \leq P(|\xi_n - \xi| \geq \delta)$$

А это уже, так как у нас есть сходимость по вероятности $\rightarrow 0$. И заметим, что

$$P(\xi_n, \xi \notin [-A, A]) \leq P(|\xi_n| > A) + P(|\xi| > A) < 2\varepsilon$$

То есть $\rightarrow 0$ при $n, A \rightarrow \infty$ Все, получили, что $P(|g(\xi_n) - g(\xi)| \geq \varepsilon) \rightarrow 0$ при $n, A \rightarrow \infty$. ■

Следствие 1. $\xi_n \xrightarrow{p} \xi \Rightarrow \xi_n \xrightarrow{d} \xi$

Доказательство. Берем предыдущее предложение. Потом используем теорему Лебега для произвольной непрерывной ограниченной g и вспоминаем эквивалентное определение сходимости по распределению. ■

Теорема 4. (Эквивалентное определение сходимости почти наверное)

$$\xi_n \xrightarrow{n.n.} \xi \Leftrightarrow \forall \varepsilon > 0: \lim_{n \rightarrow \infty} P\left(\sup_{k \geq n} |\xi_k - \xi| > \varepsilon\right) = 0$$

Доказательство. Рассмотрим следующие события:

$$A_k^\varepsilon = \{|\xi_k - \xi| > \varepsilon\}$$

$$A^\varepsilon = \bigcap_{n=1}^{\infty} \bigcup_{k \geq n} A_k^\varepsilon$$

Заметим, что:

$$\left\{ \sup_{k \geq n} |\xi_k - \xi| > \varepsilon \right\} = \{\exists k \geq n : |\xi_k - \xi| > \varepsilon\} = \bigcup_{k \geq n} A_k^\varepsilon$$

$$\left\{ \lim_{n \rightarrow \infty} \xi_n \neq \xi \right\} = \{\exists \varepsilon > 0 \forall n \exists k \geq n : |\xi_k - \xi| \geq \varepsilon\} = \bigcup_{m=1}^{\infty} \bigcap_{n=1}^{\infty} \bigcup_{k \geq n} A_k^{\varepsilon=\frac{1}{m}} = \bigcup_{m=1}^{\infty} A^{\frac{1}{m}}$$

Тогда имеем:

$$\xi_n \xrightarrow{\text{п.н.}} \xi \Leftrightarrow P\left(\lim_{n \rightarrow \infty} \xi_n \neq \xi\right) = 0 \Leftrightarrow P\left(\bigcup_{m=1}^{\infty} A^{\frac{1}{m}}\right) = 0 \Leftrightarrow \forall m \ P\left(A^{\frac{1}{m}}\right) = 0 \Leftrightarrow \forall \varepsilon > 0 \ P(A^\varepsilon) = 0 \Leftrightarrow$$

Теперь заметим вложенность последовательности событий $B_n^\varepsilon = \bigcup_{k \geq n} A_k^\varepsilon$ и, взглянув на определение

A^ε , по теореме о непрерывности вероятностной меры продолжаем цепочку:

$$\Leftrightarrow \lim_{n \rightarrow \infty} P\left(\bigcup_{k \geq n} A_k^\varepsilon\right) = 0 \Leftrightarrow \lim_{n \rightarrow \infty} P\left(\sup_{k \geq n} |\xi_k - \xi| > \varepsilon\right) = 0$$

■

Теперь приведем некоторые примеры, опровергающие остальные следствия сходимостей

Пример 1.

$$\xi_n \xrightarrow{d} \xi \not\Rightarrow \xi_n \xrightarrow{P} \xi$$

Пусть $\Omega = \{\omega_1, \omega_2\}$, $P(\{\omega_i\}) = \frac{1}{2}$. Определим $\forall n \ \xi_n(\omega_i) = (-1)^i$. Положим $\xi = -\xi_n$. Тогда $\forall f$ непрерывной и ограниченной:

$$\mathbb{E}f(\xi_n) = \frac{f(1) + f(-1)}{2} = \mathbb{E}f(\xi)$$

То есть $\xi_n \xrightarrow{d} \xi$. Однако $\forall n \ |\xi_n - \xi| = 2$, то есть $\xi_n \not\xrightarrow{P} \xi$

Пример 2.

$$\xi_n \xrightarrow{P} \xi \not\Rightarrow \xi_n \xrightarrow{\text{п.н.}} \xi$$

Возьмем $\Omega = [0, 1]$, $\xi_{2^n+p} = \text{Ind}_{[\frac{p}{2^n}, \frac{p+1}{2^n}]}$, $0 \leq p < 2^n$. Ясно, что $\xi_n \xrightarrow{P} \xi$, так как

$$\lim_{n \rightarrow \infty} P(\xi_n > 0) = \lim_{n \rightarrow \infty} \frac{1}{2^{\lfloor \log n \rfloor}} = 0$$

, но $\xi_n \not\xrightarrow{\text{п.н.}} 0$, так как для любого исхода ω существует бесконечно много n , что $\xi_n(\omega) = 1$. Теперь осталось посмотреть на теорему 4 и все станет ясно.

Пример 3.

$$\xi_n \xrightarrow{d} \xi \not\Rightarrow \xi_n \xrightarrow{\text{п.н.}} \xi$$

Если бы следствие имело место, то отсюда вытекало бы, что:

$$\xi_n \xrightarrow{d} \xi \not\Rightarrow \xi_n \xrightarrow{P} \xi$$

противоречие

2 Характеристические функции

Определение 2. Характеристической функцией случайной величины ξ называется функция:

$$\varphi_{\xi}(t) = \mathbb{E}e^{it\xi} = \mathbb{E}(\cos(t\xi) + i \sin(t\xi))$$

Предложение 2. (Свойства характеристических функций)

1. $\varphi_{\xi}(0) = 1, |\varphi_{\xi}(t)| \leq 1 \forall t \in \mathbb{R}$
2. $\varphi_{a\xi+b}(t) = e^{itb}\varphi_{\xi}(at)$
3. если ξ_1, \dots, ξ_n — независимые случайные величины и $S = \xi_1 + \dots + \xi_n$, то

$$\varphi_S(t) = \varphi_{\xi_1}(t) \cdots \varphi_{\xi_n}(t)$$

Доказательство. .

1. Понятно, так как в матожидании могут быть только комплексные числа с модулем ≤ 1 .
2. $\varphi_{a\xi+b}(t) = \mathbb{E}e^{it(a\xi+b)} = e^{itb}\mathbb{E}e^{i(at)\xi} = e^{itb}\varphi_{\xi}(at)$
3. $\varphi_S(t) = \mathbb{E}(e^{it\xi_1} \dots e^{it\xi_n}) = \mathbb{E}e^{it\xi_1} \dots \mathbb{E}e^{it\xi_n} = \varphi_{\xi_1}(t) \cdots \varphi_{\xi_n}(t)$

■

Пример 4. Вычислим $\varphi_{\xi}(t)$, где $\xi \sim N(0, 1)$:

$$\varphi_{\xi}(t) = \mathbb{E}e^{it\xi} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \cos(tx) e^{-\frac{x^2}{2}} dx + \frac{i}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \sin(tx) e^{-\frac{x^2}{2}} dx$$

Заметим, что $\int_{-\infty}^{+\infty} \sin(tx) e^{-\frac{x^2}{2}} dx = 0$, так как это интеграл от нечетной функции по симметричному промежутку. Тогда имеем:

$$\varphi_{\xi}(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \cos(tx) e^{-\frac{x^2}{2}} dx$$

Возьмем производную по t :

$$\begin{aligned} \varphi'_{\xi}(t) &= -\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} x \sin(tx) e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \sin(tx) d\left(e^{-\frac{x^2}{2}}\right) = \\ &= \frac{1}{\sqrt{2\pi}} \sin(tx) e^{-\frac{x^2}{2}} \Big|_{-\infty}^{+\infty} - \frac{t}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \cos(tx) e^{-\frac{x^2}{2}} dx = 0 - \frac{t}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} \cos(tx) e^{-\frac{x^2}{2}} dx = -t\varphi_{\xi}(t) \end{aligned}$$

Теперь надо решить дифференциальное уравнение:

$$\varphi'_{\xi}(t) = -t\varphi_{\xi}(t)$$

$$\frac{\varphi'_{\xi}(t)}{\varphi_{\xi}(t)} = -t$$

Интегрируем обе части:

$$\int \frac{d(\varphi_{\xi}(t))}{\varphi_{\xi}(t)} = \ln|\varphi_{\xi}(t)| + C = \int -tdt = -\frac{t^2}{2}$$

$$\varphi_{\xi}(t) = C'e^{-\frac{t^2}{2}}$$

$$\varphi_{\xi}(0) = 1 = C' \Rightarrow C' = 1$$

(Ответ никак нулевым быть не может, поэтому, когда мы поделили на хар функцию ничего плохого не произошло)

Предложение 3. Пусть случайная величина ξ обладает конечным k -тым моментом, то есть $\mathbb{E}|\xi|^k < \infty$. Тогда φ имеет непрерывную k -тую производную и $\varphi^{(k)}(0) = i^k \mathbb{E}\xi^k$

Доказательство. Заметим, что:

$$\left| \frac{e^{i\Delta t\xi} - 1}{\Delta t} \right| \leq \frac{\sqrt{(\cos(\Delta t\xi) - 1)^2 + \sin^2(\Delta t\xi)}}{|\Delta t|} = \frac{\sqrt{2 - 2\cos(\Delta t\xi)}}{|\Delta t|} = \frac{2|\sin(\frac{\Delta t\xi}{2})|}{\Delta t} \leq \frac{2 \cdot \frac{|\Delta t\xi|}{2}}{|\Delta t|} = |\xi|$$

Возьмем вместо Δt последовательность $a_n \rightarrow 0$. Получим, что последовательность случайных величин, сходящихся почти наверное и ее предел ($i\xi$) ограничены случайной величиной (ξ) с конечным ожиданием, получаем по теореме Лебега:

$$\mathbb{E} \frac{e^{ian\xi} - 1}{a_n} \rightarrow \mathbb{E}i\xi$$

Теперь посчитаем производную хар функции:

$$\varphi'(t) = \lim_{\Delta t \rightarrow 0} \frac{\varphi(t + \Delta t) - \varphi(t)}{\Delta t} = \lim_{\Delta t \rightarrow 0} \mathbb{E} e^{it\xi} \cdot \frac{e^{i\Delta t\xi} - 1}{\Delta t} = i\mathbb{E} e^{it\xi} \xi$$

Теперь очевидна непрерывность первой производной и $\varphi'(0) = i\mathbb{E}\xi$, для производных высших порядков аналогично

■

Теорема 5.

$$\xi_n \xrightarrow{d} \xi \Leftrightarrow \forall t \lim_{n \rightarrow \infty} \varphi_{\xi_n}(t) = \varphi_{\xi}(t)$$

Доказательство. \Rightarrow

Очевидно по Теореме 1

\Leftarrow

Докажем при условии $\sup_n \mathbb{E}\xi_n^2 \leq C < \infty$. По неравенству Чебышева:

$$P(|\xi_n| \geq A) \leq \frac{\mathbb{E}\xi_n^2}{A^2} \leq \frac{C}{A^2}$$

Пусть f — ограниченная непрерывная функция и $M = \sup|f|$. Из записанного неравенства Чебышева следует, что $\forall \varepsilon > 0 \exists A$:

$$P(|\xi_n| \geq A) \leq \varepsilon, \quad P(|\xi| \geq A) \leq \varepsilon$$

Пусть непрерывная ограниченная f_ε совпадает с f на $[-A, A]$, потом от $-A-1$ до $-A$ и от $A+1$ до A она будет прямой из 0 в $f(-A)$ и $f(A)$ соответственно, а дальше будет повторять этот шаблон (периодическая). Заметим, что:

$$|\mathbb{E}f_\varepsilon(\xi_n) - \mathbb{E}f(\xi_n)| < 2M\varepsilon, \quad |\mathbb{E}f_\varepsilon(\xi) - \mathbb{E}f(\xi)| < 2M\varepsilon$$

Теперь равномерно приблизим f_ε комбинацией \sin, \cos (знаем с матана, что периодическую можно так приблизить). А из сходимости хар функции мы знаем, что:

$$\lim_{n \rightarrow \infty} \mathbb{E} \sin(\xi_n) = \mathbb{E} \sin(\xi)$$

$$\lim_{n \rightarrow \infty} \mathbb{E} \cos(\xi_n) = \mathbb{E} \cos(\xi)$$

То есть получаем $\lim_{n \rightarrow \infty} \mathbb{E}f_\varepsilon(\xi_n) = \mathbb{E}f_\varepsilon(\xi)$. В итоге, вспоминая те неравенства с $2M\varepsilon$ и устремляя $n \rightarrow \infty$:

$$\mathbb{E}f(\xi) - 4M\varepsilon \leq \inf_{n \rightarrow \infty} \lim \mathbb{E}f(\xi_n) \leq \sup_{n \rightarrow \infty} \lim \mathbb{E}f(\xi_n) \leq \mathbb{E}f(\xi) + 4M\varepsilon$$

Устремляя $\varepsilon \rightarrow 0$, получаем $\lim_{n \rightarrow \infty} \mathbb{E}f(\xi_n) = \mathbb{E}f(\xi)$, что доказывает сходимость по распределению.

■

Следствие 2. $\varphi_\xi \equiv \varphi_\eta \Rightarrow F_\xi \equiv F_\eta$

Доказательство. Предыдущая теорема + Теорема 1. ■

Теорема 6. (Центральная предельная теорема)

Пусть ξ_n — последовательность независимых одинаково распределенных случайных величин, причем $\mathbb{E}\xi_1 = \mu$, $\mathbb{D}\xi_1 = \sigma^2$. Тогда $\forall x$:

$$\lim_{n \rightarrow \infty} P\left(\frac{\xi_1 + \dots + \xi_n - n\mu}{\sigma\sqrt{n}} \leq t\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{x^2}{2}} dx$$

(справа записана $F(t)$ — функция распределения случайной величины с распределением $N(0, 1)$)

Доказательство. Переходя к случайным величинам $\xi_i = \frac{\xi_i - \mu}{\sigma}$ далее будем считать, что $\mathbb{E}\xi_i = 0$ и $\mathbb{D}\xi_i = 1$. Пусть φ — хар функция случайной величины ξ_1 . Тогда хар функция случайной величины

$$\frac{\xi_1 + \dots + \xi_n}{\sqrt{n}}$$

равна

$$\varphi_n(t) = \left(\varphi\left(\frac{t}{\sqrt{n}}\right)\right)^n$$

Разложим $\varphi\left(\frac{t}{\sqrt{n}}\right)$ в ряд Тейлора в 0 (при $n \rightarrow \infty$), помним предложение 3:

$$\varphi\left(\frac{t}{\sqrt{n}}\right) = \varphi(0) + x\varphi'(0) + \dots = 1 + 0 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)$$

Следовательно получаем:

$$\varphi_n(t) = \left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n = \left(1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^{-\frac{2n}{t^2} \cdot \left(-\frac{t^2}{2}\right)} \xrightarrow{n \rightarrow \infty} e^{-\frac{t^2}{2}}$$

Получили характеристическую функцию нормального распределения, то есть и функции распределения должны совпадать. ■

3 Неравенство типа Хефдинга-Чернова

Теорема 7. (Неравенство Хефдинга-Чернова)

Пусть случайные величины ξ_1, \dots, ξ_n независимы и $a_i \leq \xi_i \leq b_i$. Тогда для случайной величины $S_n = \xi_1 + \dots + \xi_n$ и для каждого $t > 0$ выполнено

$$P(|S_n - \mathbb{E}S_n| \geq t) \leq 2 \exp \left(-\frac{t^2}{4 \sum_{i=1}^n (b_i - a_i)^2} \right)$$

Доказательство. Пусть $\eta_i = \xi_i - \mathbb{E}\xi_i$, тогда $|\eta_i| \leq b_i - a_i$. Заметим, что для каждого $\lambda > 0$ (просто домножили и взяли экспоненту):

$$P(S_n - \mathbb{E}S_n \geq t) = P\left(\sum_{i=1}^n \eta_i \geq t\right) = P(e^{\lambda \sum \eta_i} \geq e^{\lambda t})$$

Теперь применим неравенство Маркова:

$$P(e^{\lambda \sum \eta_i} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E}e^{\lambda \sum \eta_i}$$

Вспомним, что η_1, \dots, η_n независимы:

$$e^{-\lambda t} \mathbb{E}e^{\lambda \sum \eta_i} = e^{-\lambda t} \prod \mathbb{E}e^{\lambda \eta_i}$$

Оценим каждый множитель $\mathbb{E}e^{\lambda \eta_i}$ отдельно. Разложим его в ряд Тейлора:

$$\mathbb{E}e^{\lambda \eta_i} = 1 + \lambda \mathbb{E}\eta_i + \lambda^2 \mathbb{E}\eta_i^2 + \sum_{k=3}^{\infty} \frac{1}{k!} \lambda^k \mathbb{E}\eta_i^k \leq 1 + \lambda^2 (b_i - a_i)^2 + \sum_{k=3}^{\infty} \frac{1}{k!} \lambda^k (b_i - a_i)^k$$

Докажем, что при $R > 0$:

$$1 + \frac{1}{2}R^2 + \sum_{k=3}^{\infty} \frac{1}{k!} R^k \leq e^{R^2}$$

Если $R > 1$:

$$1 + \frac{1}{2}R^2 + \sum_{k=3}^{\infty} \frac{1}{k!} R^k = 1 + \frac{1}{2}R^2 + \sum_{k=2}^{\infty} \frac{1}{k!} R^{2k} \left(\frac{k!}{(2k-1)!} R^{-1} + \frac{n!}{(2n)!} \right) \leq 1 + \frac{1}{2}R^2 + \sum_{k=2}^{\infty} \frac{1}{k!} R^{2k} = e^{R^2}$$

Если же $R \leq 1$:

$$1 + \frac{1}{2}R^2 + \sum_{k=3}^{\infty} \frac{1}{k!} R^k \leq 1 + \frac{1}{2}R^2 + \sum_{k=3}^{\infty} \frac{1}{2^{k-1}} R^2 = 1 + R^2 \leq e^{R^2}$$

Таким образом:

$$P(S_n - \mathbb{E}S_n \geq t) \leq \exp \left(-\lambda t + \lambda^2 \sum_{i=1}^n (b_i - a_i)^2 \right)$$

Взяв $\lambda = \frac{t}{2 \sum (a_i - b_i)^2}$ получим желаемое неравенство. Для $P(S_n - \mathbb{E}S_n \geq t)$ получим такую же оценку, и, объединяя их, получим оценку на модуль, только придется домножить оценку на 2. ■

Следствие 3. Пусть $\xi_i \sim \text{Bern}(p)$ – набор n независимых случайных величин, $S_n = \xi_1 + \dots + \xi_n$, тогда

$$P\left(\left|\frac{S_n}{n} - p\right| \geq t\right) \leq 2e^{-\frac{nt^2}{4}}$$

Доказательство. Разделим каждую случайную величину на n , тогда $\mathbb{E} \frac{S_n}{n} = p$, а $\sum_{i=1}^n (a_i - b_i)^2 = n \cdot \frac{1}{n^2} = \frac{1}{n}$. Подставляем и получаем, нужное неравенство ■

Пример 5. Пусть в ящике какое-то количество черных и белых шаров. Каким должен быть размер выборки, чтобы оценить долю белых шаров с малой погрешностью? Пусть ξ_i — бернуллевская случайная величина, равная 1, если шар белого цвета и 0, если цвет черный. Мы хотим оценить вероятность успеха p . По неравенству выше:

$$P \left(\left| \frac{S_n}{n} - p \right| \geq t \right) \leq 2e^{-\frac{nt^2}{4}} \leq \varepsilon$$

Тогда при размере выборки $n = O \left(\frac{\ln \frac{1}{\varepsilon}}{t^2} \right)$ выборочное среднее приближает реальную долю белых шаров с точностью t с вероятностью более $1 - \varepsilon$ (то есть вероятность, что наша оценка верна $\geq 1 - \varepsilon$)

4 Теоремы непрерывности

Для применения ЦПТ на практике важную роль играют так называемые теоремы о непрерывности.

Предложение 4. Если последовательность случайных величин $\xi_n \xrightarrow{d} \xi$, то для всякой непрерывной g $g(\xi_n) \xrightarrow{d} g(\xi)$

Доказательство. Следует из Теоремы 1 (эквивалентное определение сходимости по распределению). ■

Лемма 1. Пусть X, Y, Z – случайные величины. Тогда

$$P(X + Y \leq t) \leq P(X + Z \leq t + \varepsilon) + P(|Y - Z| \geq \varepsilon), \quad \forall t \in \mathbb{R}, \forall \varepsilon > 0$$

Доказательство. Заметим, что

$$\begin{aligned} P(X + Y \leq t) &\leq P(X + Y \leq t, |Y - Z| \leq \varepsilon) + P(X + Y \leq t, |Y - Z| \geq \varepsilon) \leq \\ &\leq P(X + Z - \varepsilon \leq t) + P(|Y - Z| \geq \varepsilon) \end{aligned}$$

■

Предложение 5. Если $\xi_n \xrightarrow{P} a = \text{const}$ и $\eta_n \xrightarrow{d} \eta$, то $\xi_n \eta_n \xrightarrow{d} a\eta$, $\xi_n + \eta_n \xrightarrow{d} a + \eta$

Доказательство. Докажем утверждение для суммы. Пусть $\varepsilon > 0$, тогда по лемме имеем:

$$P(\xi_n + \eta_n \leq t) \leq F_{\eta_n}(t - a + \varepsilon) + P(|\xi_n - a| \geq \varepsilon)$$

и

$$P(\xi_n + \eta_n \leq t) \geq F_{\eta_n}(t - a - \varepsilon) - P(|\xi_n - a| \geq \varepsilon)$$

Устремляя сначала $n \rightarrow \infty$, а затем $\varepsilon \rightarrow 0$. Из сходимости по вероятности получаем, что $P(|\xi_n - a| \geq \varepsilon) \rightarrow 0$. Тогда в итоге имеем:

$$\begin{aligned} \lim (F_{\eta_n}(t - a - \varepsilon) - P(|\xi_n - a| \geq \varepsilon)) &\leq \lim F_{\xi_n + \eta_n}(t) \leq \lim (F_{\eta_n}(t - a + \varepsilon) + P(|\xi_n - a| \geq \varepsilon)) \\ \lim F_{\xi_n + \eta_n}(t) &= F_{\eta}(t - a) = F_{a + \eta}(t) \end{aligned}$$

Теперь докажем утверждение для произведения. Пусть $a = 0$ (случай, когда $a \neq 0$ выводится из суммы $(\xi_n - a)\eta_n$ и $a\eta_n$). Теперь заметим, что $\forall \varepsilon > 0 \forall C > 0$ верно включение:

$$\{|\xi_n \eta_n| > \varepsilon\} \subseteq \{|\eta_n| > C\} \cup \left\{|\xi_n| > \frac{\varepsilon}{C}\right\}$$

(Пояснение: это верно, так как пересечение отрицания обоих событий точно приводит к противоречию). Тогда, переходя к вероятностям, получаем:

$$P(|\xi_n \eta_n| > \varepsilon) \leq 1 - F_{\eta_n}(C) + F_{\eta_n}(-C) + P\left(|\xi_n| > \frac{\varepsilon}{C}\right)$$

Устремляя сначала $n \rightarrow \infty$, а затем $C \rightarrow \infty$, получаем, что $\xi_n \eta_n \xrightarrow{P} 0 \Rightarrow \xi_n \eta_n \xrightarrow{d} 0$. ■

Пример 6. (Выборочная дисперсия)

Пусть задана последовательность независимых и одинаково распределенных случайных величин ξ_i , причем $\mathbb{E}\xi_i = \mu$ и $\mathbb{D}\xi_i = \sigma^2$. Тогда последовательность случайных величин

$$s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (\xi_i - \bar{\xi}_n)^2 \xrightarrow{P} \sigma^2$$

где $\bar{\xi}_n = \frac{\xi_1 + \dots + \xi_n}{n}$ (умножаем на $\frac{1}{n-1}$, а не на $\frac{1}{n}$, чтобы $\mathbb{E}s_n^2 = \sigma^2$, то есть таким образом посчитанная дисперсия по вероятности сходится к именно тому, чему и надо, в другом случае будет небольшое смещение в $\frac{n-1}{n}$ раз, но с увеличением n разница в любом случае будет стираться). Действительно:

$$s_n^2 = \frac{1}{n-1} \left(\sum_{i=1}^n \xi_i^2 - 2n\bar{\xi}_n \cdot \frac{1}{n} \sum_{i=1}^n \xi_i + n\bar{\xi}_n^2 \right) = \frac{1}{n-1} \left(\sum_{i=1}^n \xi_i^2 - n\bar{\xi}_n^2 \right) = \frac{n}{n-1} \cdot \frac{1}{n} \sum_{i=1}^n \xi_i^2 - \frac{n}{n-1} \bar{\xi}_n^2$$

Теперь заметим, что по ЗБЧ:

$$\frac{1}{n} \sum_{i=1}^n \xi_i^2 \xrightarrow{P} \sigma^2 + \mu, \quad \bar{\xi}_n \xrightarrow{P} \mu$$

Получили искомую сходимость

Пример 7. Пусть задана последовательность независимых и одинаково распределенных случайных величин ξ_i , причем $\mathbb{E}\xi_i = \mu$ и $\mathbb{D}\xi_i = \sigma^2 > 0$. Тогда из ЦПТ следует, что:

$$\frac{\xi_1 + \dots + \xi_n - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{\xi}_n - \mu)}{\sigma} \xrightarrow{d} \xi \sim N(0, 1)$$

Более того, так как $s_n^2 \xrightarrow{P} \sigma^2 > 0$, то имеет место сходимость по распределению величин:

$$\frac{\sqrt{n}(\bar{\xi}_n - \mu)}{s_n^2} \xrightarrow{d} \xi \sim N(0, 1)$$

Предложение 6. Пусть $a, h_n \in \mathbb{R}$, $\lim_{n \rightarrow \infty} h_n = 0$ и f — непрерывно дифференцируемая функция на \mathbb{R} . Если последовательность случайных величин ξ_n сходится по распределению к ξ , то:

$$\frac{f(a + h_n \xi_n) - f(a)}{h_n} \xrightarrow{d} f'(a) \xi$$

Доказательство. Имеет место равенство:

$$\begin{aligned} \frac{f(a + h_n \xi_n) - f(a)}{h_n} &= \frac{f(a + 1 \cdot h_n \xi_n) - f(a + 0 \cdot h_n \xi_n)}{h_n} = \frac{1}{h_n} \int_0^1 f(a + th_n \xi_n) d(a + th_n \xi_n) = \\ &= \xi_n \int_0^1 f(a + th_n \xi_n) dt \end{aligned}$$

Из предложения 5(самый конец) получаем, что $h_n \xi_n \xrightarrow{P} 0$. Также заметим, что функция

$$g(y) = \int_0^1 f(a + ty) dt$$

непрерывна. Следовательно по предложению 4:

$$g(h_n \xi_n) = \int_0^1 f(a + th_n \xi_n) dt \xrightarrow{P} g(0) = f'(a)$$

Теперь снова используя предложение 5, получаем нужную сходимость. ■

Пример 8. Пусть задана последовательность независимых и одинаково распределенных случайных величин ξ_i , причем $\mathbb{E}\xi_i = \mu$ и $\mathbb{D}\xi_i = \sigma^2 > 0$. Если h — непрерывно дифференцируемая функция, то

$$\sqrt{n} (h(\bar{\xi}_n) - h(\mu)) \xrightarrow{d} \xi \sim N(0, q^2), \quad q = \sigma h'(\mu)$$

Действительно, имеем равенство

$$\sqrt{n} \frac{(h(\bar{\xi}_n) - h(\mu))}{\sigma} = \frac{1}{\sigma} \cdot \frac{h(\mu + n^{-\frac{1}{2}} \sigma \zeta_n) - h(\mu)}{n^{-\frac{1}{2}}}$$

где (сходимость по ЦПТ)

$$\zeta_n = \frac{\sqrt{n} (\bar{\xi}_n - \mu)}{\sigma} \xrightarrow{d} \xi \sim N(0, 1)$$

Используем предложение 6 и получаем требуемое.

Пример 9. Пусть ξ_1, \dots, ξ_n положительные независимые одинаково распределенные случайные величины, $\mathbb{E}\xi_1 = \mu$, $0 < \mathbb{D}\xi_1 = \sigma^2 < \infty$. Рассмотрим случайную величину $S_n = \xi_1 + \dots + \xi_n$ и найдем предел в смысле сходимости по распределению у последовательности случайных величин

$$\sqrt{n} \left(\frac{n}{S_n} - \frac{1}{\mu} \right).$$

Первый способ:

$$\sqrt{n} \left(\frac{n}{S_n} - \frac{1}{\mu} \right) = -\frac{1}{\mu} \frac{n}{S_n} \sqrt{n} \left(\frac{S_n}{n} - \mu \right)$$

По ЦПТ

$$\sqrt{n} \left(\frac{S_n}{n} - \mu \right) \xrightarrow{d} \xi \sim N(0, \sigma^2)$$

По ЗБЧ

$$\frac{n}{S_n} \xrightarrow{P} \frac{1}{\mu}$$

Таким образом имеем:

$$\sqrt{n} \left(\frac{n}{S_n} - \frac{1}{\mu} \right) \xrightarrow{d} -\frac{1}{\mu} \xi \sim N\left(0, \frac{\sigma^2}{\mu^4}\right)$$

Второй способ:

Пусть $h(x) = \frac{1}{x}$, тогда

$$\sqrt{n} \left(\frac{n}{S_n} - \frac{1}{\mu} \right) = \sqrt{n} \left(h\left(\frac{S_n}{n}\right) - h(\mu) \right) \xrightarrow{d} \xi \sim N\left(0, \sigma^2 (h'(\mu))^2\right) = N\left(0, \frac{\sigma^2}{\mu^4}\right)$$

5 Многомерная характеристическая функция и ЦПТ

Определение 3. Характеристическая функция случайного вектора $\xi = (\xi_1, \dots, \xi_m)^T$ определяется равенством

$$\varphi_\xi(x) = \mathbb{E}e^{ix\xi} = \mathbb{E}e^{i\sum_{i=1}^m x_i \xi_i}$$

Предложение 7. $\varphi_\xi \equiv \varphi_\eta \Leftrightarrow \xi$ и η имеют одинаковые распределения

Доказательство. Заметим, что

$$F_\xi(x_1, \dots, x_m) = \mathbb{E}I_{\leq x_1}(\xi_1) \cdots I_{\leq x_m}(\xi_m)$$

По аналогии с одномерным случаем, нам достаточно доказать, что

$$\mathbb{E}g_1(\xi_1) \cdots g_m(\xi_m) = \mathbb{E}g_1(\eta_1) \cdots g_m(\eta_m)$$

для непрерывных периодических функций $g_k(u)$. Такие функции приближаются линейными комбинациями функций вида $e^{i\mu_k u}$. Значит, достаточно проверять совпадение выражений вида

$$\mathbb{E} \exp(i\mu_1 \xi_1 + \cdots + i\mu_m \xi_m) = \mathbb{E} \exp(i\mu_1 \eta_1 + \cdots + i\mu_m \eta_m)$$

А это у нас есть (это хар функции). ■

Следствие 4. Случайные величины ξ_1, \dots, ξ_m независимы тогда и только тогда, когда

$$\varphi_\xi(y_1, \dots, y_m) = \varphi_{\xi_1}(y_1) \cdots \varphi_{\xi_m}(y_m)$$

Доказательство. \Rightarrow

$$\varphi_\xi(y_1, \dots, y_m) = \mathbb{E}e^{i(\xi_1 y_1 + \cdots + \xi_m y_m)} = \mathbb{E}e^{i\xi_1 y_1} \cdots e^{i\xi_m y_m} =$$

В силу независимости ξ_i

$$= \mathbb{E}e^{i\xi_1 y_1} \cdots \mathbb{E}e^{i\xi_m y_m} = \varphi_{\xi_1}(y_1) \cdots \varphi_{\xi_m}(y_m)$$

\Leftarrow

Сделаем новый вектор (η_1, \dots, η_m) , так что:

1. Распр $\eta_i =$ распр $\xi_i \quad \forall i \in \{1, \dots, m\}$
2. η_1, \dots, η_m независимы

Определим $F(y) = F_{\eta_1}(y_1) \cdots F_{\eta_m}(y_m)$. Тогда мы знаем, что существует вектор, у которого такая функция распределения, из чего непременно следует независимость η_1, \dots, η_m

Посчитаем хар. функцию $\eta = (\eta_1, \dots, \eta_m)$

$$\varphi_\eta(y) = \left[\begin{array}{l} \text{в силу} \\ \text{нез - сти } \eta_i \end{array} \right] = \varphi_{\eta_1}(y_1) \cdots \varphi_{\eta_m}(y_m) = \varphi_{\xi_1}(y_1) \cdots \varphi_{\xi_m}(y_m) = \varphi_\xi(y)$$

По предыдущему предложению и независимости $\eta_1, \dots, \eta_m \Rightarrow \xi_1, \dots, \xi_m$ независимы. ■

Теорема 8. Пусть последовательность независимых одинаково распределенных случайных векторов $\xi^n = (\xi_1^n, \dots, \xi_m^n) \in \mathbb{E}$ имеют конечные

$$\mathbb{E}\xi_i^1 = \mu_i, \quad r_{ij} = \text{cov}(\xi_i^1, \xi_j^1)$$

Тогда величины

$$\eta_i^n = \frac{\xi_i^1 + \dots + \xi_i^n - n\mu_i}{\sqrt{n}}$$

таковы, что последовательность векторов $\eta^n = (\eta_1^n, \dots, \eta_m^n) \xrightarrow{d} \eta$, характеристическая функция которого имеет вид

$$\varphi_\eta(y) = \exp\left(-\frac{\langle yR, y \rangle}{2}\right), \quad R = (r_{ij})$$

Доказательство. В векторной форме:

$$\eta^n = \frac{\sum_{s=1}^n \xi^s - \mu n}{\sqrt{n}}$$

Запишем хар. функцию:

$$\varphi_{\eta^n}(t) = \varphi_{(\xi^1 - \mu + \dots + \xi^n - \mu)/\sqrt{n}}(t) = \varphi_{\xi^1 - \mu + \dots + \xi^n - \mu}\left(\frac{t}{\sqrt{n}}\right) =$$

В силу независимости ξ_i и их одинаковой распределенности

$$= \left(\varphi_{\xi^1 - \mu}\left(\frac{t}{\sqrt{n}}\right)\right)^n$$

Напоминание. Пусть $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$

$x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ и $a = (a_1, a_2, \dots, a_n) \in \mathbb{R}^n$. Тогда ряд Тейлора функции F в точке a это

$$\begin{aligned} F(x) &= F(a) + \sum_{i=1}^n \frac{dF(a)}{dx_i} (x_i - a_i) + \frac{1}{2} \sum_{i,j=1}^n \frac{d^2 F(a)}{dx_i dx_j} (x_i - a_i)(x_j - a_j) \\ &+ \dots + \frac{1}{k!} \sum_{i_1, \dots, i_k=1}^n \frac{d^k F(a)}{dx_{i_1} \dots dx_{i_k}} (x_{i_1} - a_{i_1}) \dots (x_{i_k} - a_{i_k}) + R_k(x - a, a) \end{aligned}$$

Разложим в ряд Тейлора:

$$\left(\varphi_{\xi^1 - \mu}\left(\frac{t}{\sqrt{n}}\right)\right)^n = \left(1 + \left\langle \nabla \varphi_{\xi^1 - \mu}(0), \frac{t}{\sqrt{n}} \right\rangle + \frac{1}{2} \cdot D^2 \varphi_{\xi^1 - \mu}(0) \left\langle \frac{t}{\sqrt{n}}, \frac{t}{\sqrt{n}} \right\rangle + o\left(\frac{1}{n}\right)\right)^n$$

Рассмотрим на 2-мерном случае (на других аналогично):

$$\varphi_\xi(t_1, t_2) = \mathbb{E}e^{it_1\xi_1 + it_2\xi_2}$$

Первая производная:

$$\frac{d}{dt_j} \varphi_\xi(t) = i\mathbb{E}\xi_j e^{it_1\xi_1 + it_2\xi_2}; \quad \frac{d}{dt_j} \varphi_\xi(0) = i\mathbb{E}\xi_j$$

В нашем случае нетрудно понять, что $\nabla \varphi_{\xi^1 - \mu}(0) = 0$, так как у нас ξ это $\xi^1 - \mu$, а $i\mathbb{E}(\xi_i^1 - \mu_i) = 0$

Вторая производная:

$$\frac{d^2}{dt_j dt_s} \varphi_\xi(t) = -\mathbb{E}\xi_j \xi_s e^{it_1\xi_1 + it_2\xi_2}; \quad \frac{d^2}{dt_j dt_s} \varphi_\xi(0) = -\mathbb{E}\xi_j \xi_s$$

В нашем случае $-\mathbb{E}(\xi_j^1 - \mu_j)(\xi_s^1 - \mu_s) = -r_{js}$

Получаем:

$$\left(1 - \frac{1}{2}\langle Rt, t \rangle \frac{1}{n} + o\left(\frac{1}{n}\right)\right)^n \xrightarrow{n \rightarrow \infty} e^{-\frac{1}{2}\langle Rt, t \rangle}$$

■

6 Многомерное нормальное распределение

Определение 4. Случайный вектор $\xi \in \text{Mat}_{m \times 1}$ имеет *нормальное распределение* или является *гауссовским*, если $\forall x \in \mathbb{R}^m$

$$\varphi_\xi(x) = \mathbb{E} e^{ix\xi} = e^{ix\mu - \frac{1}{2}xRx^T}$$

где $\mu = (\mu_1, \dots, \mu_m)^T$, $R \in \text{Mat}_{m \times m}$ – симметричная неотрицательно определенная. Далее кратко пишем

$$\xi \sim N(\mu, R)$$

Определение 5. Пусть $\xi \in \text{Mat}_{m \times 1}$ случайный вектор. Матрица $R \in \text{Mat}_{m \times m}$ с компонентами $r_{ij} = \text{cov}(\xi_i, \xi_j)$ называется *ковариационной матрицей* вектора ξ . Можно еще написать, что

$$R = \text{cov}(\xi, \xi) = \mathbb{E}(\xi - \mathbb{E}\xi)(\xi - \mathbb{E}\xi)^T$$

Лемма 2. Симметричная неотрицательно определенная матрица $R \in \text{Mat}_{m \times m}$ является ковариационной матрицей случайного вектора-столбца $\xi \in \text{Mat}_{m \times 1}$ тогда и только тогда, когда $\forall x, y \in \mathbb{R}^m$

$$\text{cov}(x\xi, y\xi) = x\text{cov}(\xi, \xi)y^T = xRy^T$$

Доказательство. \Rightarrow

Распишем по определению ковариации двух случайных величин (у нас именно они):

$$\text{cov}(x\xi, y\xi) = \mathbb{E}[(x\xi - \mathbb{E}x\xi)(y\xi - \mathbb{E}y\xi)] = \mathbb{E}[x(\xi - \mathbb{E}\xi)y(\xi - \mathbb{E}\xi)] =$$

Транспонируя скаляр, получаем тот же скаляр:

$$= \mathbb{E}[x(\xi - \mathbb{E}\xi)(y(\xi - \mathbb{E}\xi))^T] = \mathbb{E}[x(\xi - \mathbb{E}\xi)(\xi - \mathbb{E}\xi)^T y^T] = x\mathbb{E}[(\xi - \mathbb{E}\xi)(\xi - \mathbb{E}\xi)^T]y^T = x\text{cov}(\xi, \xi)y^T$$

\Leftarrow

Возьмем $x = e_i$, $y = e_j$ (базисные единичные вектора). Тогда из данного равенства получим:

$$\text{cov}(e_i\xi, e_j\xi) = \text{cov}(\xi_i, \xi_j) = e_i R e_j = r_{ij}$$

Следовательно $R = \text{cov}(\xi, \xi)$ по определению. ■

Предложение 8. $\forall A \in \text{Mat}_{m \times m} \forall b \in \text{Mat}_{m \times 1}$ и $\xi \in \text{Mat}_{m \times 1}$ – случайного вектора, верно:

$$\text{cov}(A\xi + b, A\xi + b) = AR_\xi A^T$$

Доказательство. Распишем по определению:

$$\begin{aligned} \text{cov}(A\xi + b, A\xi + b) &= \mathbb{E}[(A\xi + b - \mathbb{E}(A\xi + b))(A\xi + b - \mathbb{E}(A\xi + b))^T] = \\ &= \mathbb{E}[(A\xi + b - b - \mathbb{E}A\xi)(A\xi + b - b - \mathbb{E}A\xi)^T] = \mathbb{E}[(A\xi - \mathbb{E}A\xi)(A\xi - \mathbb{E}A\xi)^T] = \\ &= A\mathbb{E}[(\xi - \mathbb{E}\xi)(\xi - \mathbb{E}\xi)^T]A^T = AR_\xi A^T \end{aligned}$$

■

Следствие 5. Если вектор $\xi \sim N(\mu, R)$, то вектор $A\xi + b \sim N(A\mu + b, AR_\xi A^T)$

Теорема 9. Вектор $\xi \in \text{Mat}_{m \times 1}$ имеет нормальное распределение тогда и только тогда, когда $\forall x \in \mathbb{R}^m$ случайная величина $x\xi$ имеет нормальное распределение

Доказательство. \Rightarrow

Если ξ нормальный вектор, то

$$\begin{aligned}\varphi_{x\xi}(t) &= \mathbb{E}e^{itx\xi} = \varphi_{\xi}(tx) = \exp\left(-\frac{1}{2}txR(tx)^T + itx\mu\right) = \\ &= \exp\left(-\frac{1}{2}t^2xRx^T + itx\mu\right)\end{aligned}$$

Получили хар функцию нормального распределения $x\xi \sim N(x\mu, xRx^T)$.

\Leftarrow

В обратную сторону:

$$\begin{aligned}\varphi_{\xi}(x) &= \mathbb{E}e^{ix\xi} = \varphi_{x\xi}(1) = \exp\left(-\frac{1}{2}\mathbb{D}x\xi + i\mathbb{E}x\xi\right) = \exp\left(-\frac{1}{2}\text{cov}(x\xi, x\xi) + ix\mu\right) = \\ &= \exp\left(-\frac{1}{2}xRx^T + ix\mu\right)\end{aligned}$$

, где $R = \text{cov}(\xi, \xi)$, $\mu = \mathbb{E}\xi$. Последний переход вытекает из леммы2. ■

Следствие 6. Если $\xi \sim N(\mu, R)$, то $R = \text{cov}(\xi, \xi)$, $\mu = \mathbb{E}\xi$.

Следствие 7. Если вектор $\xi = (\xi_1, \xi_2)$ имеет нормальное распределение и $\text{cov}(\xi_1, \xi_2) = 0$, то случайные величины ξ_1 и ξ_2 независимы.

Доказательство. Пусть

$$\mu = \mathbb{E}\xi = (\mu_1, \mu_2)$$

Заметим, что

$$R = \text{cov}(\xi, \xi) = \begin{pmatrix} \text{cov}(\xi_1, \xi_1) & 0 \\ 0 & \text{cov}(\xi_2, \xi_2) \end{pmatrix}$$

Теперь запишем хар функцию ξ :

$$\begin{aligned}\varphi_{\xi}(x_1, x_2) &= \exp\left(-\frac{1}{2}(x_1^2\mathbb{D}\xi_1 + x_2^2\mathbb{D}\xi_2) + i(x_1\mu_1 + x_2\mu_2)\right) = \\ &= \exp\left(-\frac{1}{2}x_1^2\mathbb{D}\xi_1 + ix_1\mu_1\right) \cdot \exp\left(-\frac{1}{2}x_2^2\mathbb{D}\xi_2 + ix_2\mu_2\right) = \varphi_{\xi_1}(x_1) \varphi_{\xi_2}(x_2)\end{aligned}$$

Теперь из следствия4 вытекает независимость ξ_1 и ξ_2 ■

Следствие 8. Если $\xi \sim N(\mu, R) (\in \text{Mat}_{m \times 1})$, то $\exists A \in \text{Mat}_{m \times k}$, что $\xi = A\eta + \mu$, где $\eta = (\eta_1, \dots, \eta_k)^T$, η_i — независимые $N(0, 1)$ случайные величины. Причем $AA^T = R$

Доказательство. Пусть

$$\xi' = \xi - \mu = (\xi'_1, \dots, \xi'_m)^T$$

Свели задачу к задачи нахождения ортонормированного базиса $\eta = (\eta_1, \dots, \eta_k)^T$ в подпространстве $\langle \xi'_1, \dots, \xi'_m \rangle$ со скалярным произведением $(X, Y) = \mathbb{E}XY$. Эта задача решается методом Грама-Шмидта. Получили матрицу перехода A , что

$$\xi - \mu = \xi' = A\eta$$

То есть

$$\xi = A\eta + \mu$$

Осталось пояснить $AA^T = R$:

$$R = \text{cov}(\xi, \xi) = \text{cov}(\xi - \mu, \xi - \mu) = \text{cov}(A\eta, A\eta) = A\text{cov}(\eta, \eta)A^T = AEA^T = AA^T$$

$\text{cov}(\eta, \eta) = E$, так как это ортонормированный базис. ■

Теорема 10. Если $\xi \sim N(\mu, R)$ (в этой теореме сделаем $\mu := \mu^T \in R^m$) и $\det R \neq 0$, случайный вектор ξ имеет плотность

$$\rho(x) = \frac{1}{(2\pi)^{\frac{m}{2}} \sqrt{\det R}} e^{-2^{-1}(x-\mu)R^{-1}(x-\mu)^T}$$

Доказательство. Так как $\xi = A\eta + \mu$, причем $\exists A^{-1}$, то

$$\begin{aligned} P(\xi \in B) &= P(A\eta + \mu \in B) = \frac{1}{(\sqrt{2\pi})^m} \int_{A\eta + \mu \in B} e^{-2^{-1}xx^T} dx = \\ &= \frac{1}{(2\pi)^{\frac{m}{2}}} \int_B e^{-2^{-1}(A^{-1}(x-\mu))(A^{-1}(x-\mu))^T} d(A^{-1}(x-\mu)) = \frac{1}{(2\pi)^{\frac{m}{2}} \det A} \int_B e^{-2^{-1}(A^{-1}(x-\mu))(A^{-1}(x-\mu))^T} dx \end{aligned}$$

Остается заметить, что

$$\det AA^T = (\det A)^2 = \det R$$

и что

$$\begin{aligned} A^{-1}(x-\mu)(A^{-1}(x-\mu))^T &= (x-\mu)A^{-1}(A^{-1})^T(x-\mu)^T = \\ &= (x-\mu)(AA^T)^{-1}(x-\mu)^T = (x-\mu)R^{-1}(x-\mu)^T \end{aligned}$$

■

Пример 10. Пусть $\xi = (\xi_1, \dots, \xi_n)^T$, где $\xi_i \sim N(0, \sigma^2)$ и независимы между собой (или, что то же самое $\xi \sim N(0, \sigma^2 E)$). Положим

$$\bar{\xi} = \frac{\xi_1 + \dots + \xi_n}{n}, \quad \zeta = (\xi_1 - \bar{\xi})^2 + \dots + (\xi_n - \bar{\xi})^2$$

(ζ — выборочная дисперсия). Покажем, что $\bar{\xi}$ и ζ независимы.

Пусть $U \in \text{Mat}_{n \times n}$ — ортогональная матрица ($UU^T = E$), первая строка которой имеет вид $(n^{-\frac{1}{2}}, \dots, n^{-\frac{1}{2}})$. Тогда координаты вектора $u = U\xi \sim N(0, U\sigma^2 EU^T) = N(0, \sigma^2 E)$ являются независимыми. Заметим, что $u_n = \bar{\xi}\sqrt{n}$ и что

$$u^T u = u_1^2 + \dots + u_n^2 = n\bar{\xi}^2 + u_2^2 + \dots + u_n^2 = \xi^T U^T U \xi = \xi^T \xi = \xi_1^2 + \dots + \xi_n^2$$

Иначе говоря

$$u_2^2 + \dots + u_n^2 = \xi_1^2 + \dots + \xi_n^2 - n\bar{\xi}^2$$

Теперь заметим

$$\zeta = \xi_1^2 + \dots + \xi_n^2 - 2 \sum_{i=1}^n \xi_i \bar{\xi} + n\bar{\xi}^2 = \xi_1^2 + \dots + \xi_n^2 - n\bar{\xi}^2 = u_2^2 + \dots + u_n^2$$

Так как u_1, \dots, u_n — независимы, то и $\frac{u_1}{\sqrt{n}} = \bar{\xi}$ и $u_2^2 + \dots + u_n^2 = \zeta$ тоже независимы.

Распределение величины $\chi = \eta_1^2 + \dots + \eta_n^2$, где η_i независимые с распределением $N(0, 1)$, называют распределением хи-квадрат с n степенями свободы и обозначают через χ_n^2 . Найдем плотность распределения χ_n^2 :

$$P(\chi \leq t) = (2\pi)^{-\frac{n}{2}} \int_{\eta_1^2 + \dots + \eta_n^2 \leq t} e^{-\frac{x_1^2 + \dots + x_n^2}{2}} dx =$$

Делаем сферическую замену (w_n — площадь n -мерной единичной сферы):

$$= (2\pi)^{-\frac{n}{2}} w_n \int_0^{\sqrt{t}} r^{n-1} e^{-\frac{r^2}{2}} dr$$

Тогда

$$\rho(t) = (2\pi)^{-\frac{n}{2}} w_n \cdot \frac{1}{2} t^{-\frac{1}{2}} t^{\frac{n-1}{2}} e^{-\frac{t}{2}} = \frac{1}{2} (2\pi)^{-\frac{n}{2}} w_n t^{\frac{n-2}{2}} e^{-\frac{t}{2}} \text{Ind}_{t>0}$$

7 Условные математические ожидания: дискретный случай

Предположим, что задана дискретная случайная величина

$$\xi(w) = \sum_{i=1}^n x_i \text{Ind}_{A_i}(w)$$

Рассмотрим следующую задачу: найти математическое ожидание ξ , если достоверно известно, что произошло событие B , $P(B) > 0$. Поскольку мы знаем, что событие B произошло, то надо пересчитать вероятности A_k с учетом новой информации, а именно, заменить $P(A_k)$ на $P(A_k|B)$. Таким образом, надо вычислить математическое ожидание не относительно исходной вероятностной меры P , а относительно условной вероятности $P(\cdot|B)$.

Определение 6. Имеем:

$$\mathbb{E}(\xi|B) = \sum_{i=1}^n x_i P(A_i|B) = \sum_{i=1}^n x_i \frac{\mathbb{E}(\text{Ind}_{A_i} \text{Ind}_B)}{P(B)} = \frac{\mathbb{E}(\xi \text{Ind}_B)}{P(B)}$$

Это выражение будем называть *условным математическим ожиданием относительно события B* .

Пусть теперь имеется разбиение

$$\Omega = \bigcup_{k=1}^N B_k, \quad B_k \cap B_m = \emptyset, \quad P(B_k) > 0$$

Обозначим это разбиение $\{B_k\}$ через \mathcal{B} . Удобно собрать вместе значения условных математических ожиданий $\mathbb{E}(\xi|B_k)$.

Определение 7. Рассмотрим случайную величину:

$$\Lambda(w) = \sum_{i=1}^N \text{Ind}_{B_i}(w) \mathbb{E}(\xi|B_i)$$

Если $w \in B_i$, то эта случайная величина выдает среднее значение ξ при условии, что произошло событие B_i . Величину $\Lambda(w)$ называют *условным математическим ожиданием относительно разбиения \mathcal{B}* и обозначают через $\mathbb{E}(\xi|\mathcal{B})$.

Случайную величину

$$P(A|\mathcal{B}) = \mathbb{E}(\text{Ind}_A|\mathcal{B})$$

называют условной вероятностью события A относительно разбиения \mathcal{B} . Ясно, что

$$\begin{aligned} \mathbb{E}(\xi|\mathcal{B}) &= \sum_{i=1}^N \text{Ind}_{B_i}(w) \mathbb{E}(\xi|B_i) = \sum_{i=1}^N \text{Ind}_{B_i}(w) \sum_{j=1}^n x_j P(A_j|B_i) = \sum_{j=1}^n \sum_{i=1}^N \text{Ind}_{B_i}(w) x_j P(A_j|B_i) = \\ &= \sum_{j=1}^n x_j \sum_{i=1}^N \text{Ind}_{B_i}(w) P(A_j|B_i) = \sum_{j=1}^n x_j \sum_{i=1}^N \text{Ind}_{B_i}(w) \mathbb{E}(\text{Ind}_{A_j}|B_i) = \sum_{j=1}^n x_j \mathbb{E}(\text{Ind}_{A_j}|\mathcal{B}) = \\ &= \sum_{j=1}^n x_j P(A_j|\mathcal{B}) \end{aligned}$$

Пример 11. Рассмотрим важный пример, когда $\mathcal{B} = \{B, \overline{B}\}$. Тогда

$$P(A|\mathcal{B}) = \text{Ind}_B(w) P(A|B) + \text{Ind}_{\overline{B}}(w) P(A|\overline{B})$$

Если $w \in B$, то $P(A|\mathcal{B})(w) = P(A|B)$

Теорема 11. Имеют место следующие свойства условного математического ожидания:

- (1) (линейность) $\mathbb{E}(\alpha\xi + \beta\eta|\mathcal{B}) = \alpha\mathbb{E}(\xi|\mathcal{B}) + \beta\mathbb{E}(\eta|\mathcal{B})$
- (2) (монотонность) из $\xi \leq \eta$ следует $\mathbb{E}(\xi|\mathcal{B}) \leq \mathbb{E}(\eta|\mathcal{B})$
- (3) (аналог формулы полной вероятности) $\mathbb{E}(\mathbb{E}(\xi|\mathcal{B})) = \mathbb{E}\xi$
- (4) (независимость) если случайная величина ξ не зависит от разбиения \mathcal{B} , т.е. случайные величины ξ и Ind_{B_k} независимы, то $\mathbb{E}(\xi|\mathcal{B}) = \mathbb{E}\xi$
- (5) для всякой случайной величины $\eta = \sum_{k=1}^N c_k \text{Ind}_{B_k}$ верно равенство $\mathbb{E}(\eta\xi|\mathcal{B}) = \eta\mathbb{E}(\xi|\mathcal{B})$

Доказательство. Свойства (1) и (2) следуют из того, что они верны отдельно для каждого B_k . Свойство (3) проверяется непосредственной подстановкой:

$$\begin{aligned} \mathbb{E}(\mathbb{E}(\xi|\mathcal{B})) &= \mathbb{E}\left(\sum_{i=1}^N \text{Ind}_{B_i} \mathbb{E}(\xi|B_i)\right) = \mathbb{E}\left(\sum_{i=1}^N \text{Ind}_{B_i} \frac{\mathbb{E}(\xi \text{Ind}_{B_i})}{P(B_i)}\right) = \sum_{i=1}^N \mathbb{E}(\text{Ind}_{B_i}) \frac{\mathbb{E}(\xi \text{Ind}_{B_i})}{P(B_i)} = \\ &= \sum_{i=1}^N \mathbb{E}(\xi \text{Ind}_{B_i}) = \mathbb{E}\xi \end{aligned}$$

Обоснуем пункт (4). Так как ξ и Ind_{B_k} независимы, то

$$\mathbb{E}(\xi|B_k) = \frac{\mathbb{E}(\xi \text{Ind}_{B_k})}{P(B_k)} = \frac{\mathbb{E}\xi \mathbb{E} \text{Ind}_{B_k}}{P(B_k)} = \mathbb{E}\xi$$

Следовательно,

$$\mathbb{E}(\xi|\mathcal{B}) = \sum_{k=1}^N \text{Ind}_{B_k}(w) \mathbb{E}(\xi|B_k) = \sum_{k=1}^N \text{Ind}_{B_k}(w) \mathbb{E}\xi = \mathbb{E}\xi$$

Для обоснования (5) достаточно заметить, что

$$\mathbb{E}(\eta\xi|B_k) = c_k \mathbb{E}(\xi|B_k)$$

■

Наиболее типична ситуация, когда разбиение \mathcal{B} появляется посредством некоторой случайной величины

$$\eta = \sum_{i=1}^N y_i \text{Ind}_{B_i},$$

где y_i — различные числа и $P(B_i) > 0$.

Определение 8. В этом случае $B_i = \{w : \eta(w) = y_i\}$ и условное математическое ожидание $\mathbb{E}(\xi|\mathcal{B})$ обозначают через $\mathbb{E}(\xi|\eta)$ и называют *условным математическим ожиданием относительно η* .

Несложно предъявить функцию F (это можно сделать несколькими способами), что

$$\mathbb{E}(\xi|\eta)(w) = F(\eta(w))$$

Легко видеть, что $F(y_i) = \mathbb{E}(\xi|B_i)$.

Можно воспринимать $\mathbb{E}(\xi|\eta)$ как проекцию ξ на η , а $\mathbb{E}\xi\eta$ как их скалярное произведение.

Лемма 3. Для условного математического ожидания выполнено

$$\mathbb{E}(\xi f(\eta)) = \mathbb{E}[f(\eta) \mathbb{E}(\xi|\eta)]$$

для произвольной функции f . Кроме того, если для какой-то случайной величины $\zeta = g(\eta)$ выполнено

$$\mathbb{E}(\xi f(\eta)) = \mathbb{E}(f(\eta) \zeta),$$

то $\zeta = \mathbb{E}(\xi|\eta)$ п.н.

Доказательство. По (5) и (3) из теоремы 11:

$$\mathbb{E}[f(\eta) \mathbb{E}(\xi|\eta)] = \mathbb{E}[\mathbb{E}(f(\eta) \xi|\eta)] = \mathbb{E}(f(\eta) \xi)$$

Докажем вторую часть:

$$\mathbb{E}(f(\eta) \zeta) = \mathbb{E}(\xi f(\eta)) = \mathbb{E}[f(\eta) \mathbb{E}(\xi|\eta)]$$

$$\mathbb{E}[f(\eta) (\zeta - \mathbb{E}(\xi|\eta))] = 0$$

Так как ζ и $\mathbb{E}(\xi|\eta)$ — функции от η , то возьмем $f(\eta) = \zeta - \mathbb{E}(\xi|\eta)$ и получим:

$$\mathbb{E}(\zeta - \mathbb{E}(\xi|\eta))^2 = 0,$$

то есть $\zeta = \mathbb{E}(\xi|\eta)$ п.н. ■

Теперь докажем, что $\mathbb{E}(\xi|\eta)$ и правда является проекцией ξ на η .

Предложение 9. Пусть $\mathbb{E}\xi^2 < \infty$. Условное математическое ожидание $\mathbb{E}(\xi|\eta)$ среди всех случайных величин вида $f(\eta)$ является лучшим среднеквадратическим приближением для ξ , т.е.

$$\min_{\zeta=f(\eta)} \mathbb{E}(\xi - \zeta)^2 = \mathbb{E}[\xi - \mathbb{E}(\xi|\eta)]^2$$

Доказательство. Пусть $\zeta = f(\eta)$. Так как $(\mathbb{E}(\xi|\eta) - \zeta)$ — функция от η

$$\mathbb{E}[(\xi - \mathbb{E}(\xi|\eta))(\mathbb{E}(\xi|\eta) - \zeta)] = 0,$$

то

$$\begin{aligned} \mathbb{E}(\xi - \zeta)^2 &= \mathbb{E}[(\xi - \mathbb{E}(\xi|\eta)) + (\mathbb{E}(\xi|\eta) - \zeta)]^2 = \\ &= \mathbb{E}[\xi - \mathbb{E}(\xi|\eta)]^2 + \underbrace{2\mathbb{E}[(\xi - \mathbb{E}(\xi|\eta))(\mathbb{E}(\xi|\eta) - \zeta)]}_{=0} + \mathbb{E}[\mathbb{E}(\xi|\eta) - \zeta]^2 \geq \mathbb{E}[\xi - \mathbb{E}(\xi|\eta)]^2 \end{aligned}$$

Последнее неравенство достигается взятием $\zeta = \mathbb{E}(\xi|\eta)$ ■

8 Условные математические ожидания: общий случай

Определение 9. ξ, η — случайные величины. $\mathbb{E}|\xi| < \infty$. Тогда случайная величина вида $F(\eta)$ называется *условным математическим ожиданием* $\mathbb{E}(\xi|\eta)$, если

$$\mathbb{E}[\xi f(\eta)] = \mathbb{E}[\mathbb{E}(\xi|\eta) f(\eta)]$$

для любой ограниченной f . Любые две случайные величины, удовлетворяющие этому условию почти наверное совпадают (лемма 3).

Из этого определения следует, что $\mathbb{E}(\xi|\eta)$ есть наименее отличающаяся от ξ случайная величина вида $F(\eta)$, то есть проекция ξ на η .

Предложение 10. *Предположим, что распределение случайной величины (ξ, η) задано совместной плотностью $\rho_{\xi\eta}(x, y)$. Тогда*

$$\mathbb{E}[g(\xi, \eta) | \eta = y] = \int_{-\infty}^{+\infty} g(x, y) \frac{\rho_{\xi\eta}(x, y)}{\rho_{\eta}(y)} dx$$

Доказательство. Имеет место цепочка равенств:

$$\begin{aligned} \mathbb{E}[g(\xi, \eta) f(\eta)] &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(y) \rho_{\xi\eta}(x, y) dx dy = \\ &= \int_{-\infty}^{+\infty} f(y) \underbrace{\int_{-\infty}^{+\infty} g(x, y) \frac{\rho_{\xi\eta}(x, y)}{\rho_{\eta}(y)} \rho_{\eta}(y) dy}_{=F(y)} dy = \mathbb{E}[F(\eta) f(\eta)] \end{aligned}$$

Следовательно $F(\eta) = \mathbb{E}(\xi|\eta)$ по определению. ■

Определение 10. *Условной плотностью* случайной величины ξ при условии $\eta = y_0$ называется следующая величина

$$\rho_{\xi|\eta}(x|y_0) = \frac{\rho_{\xi,\eta}(x, y_0)}{\rho_{\eta}(y_0)}$$

Теперь докажем теорему 11, только для непрерывного случая

Теорема 12. *Имеют место следующие свойства условного математического ожидания:*

- (1) (линейность) $\mathbb{E}(\alpha\xi + \beta\eta|\zeta) = \alpha\mathbb{E}(\xi|\zeta) + \beta\mathbb{E}(\eta|\zeta)$
- (2) (монотонность) из $\xi \leq \eta$ следует $\mathbb{E}(\xi|\zeta) \leq \mathbb{E}(\eta|\zeta)$
- (3) (аналог формулы полной вероятности) $\mathbb{E}(\mathbb{E}(\xi|\eta)) = \mathbb{E}\xi$
- (4) (независимость) если случайные величины ξ и η , то $\mathbb{E}(\xi|\eta) = \mathbb{E}\xi$
- (5) для всякой случайной величины $\zeta = g(\eta)$ верно равенство $\mathbb{E}(\zeta\xi|\eta) = \zeta\mathbb{E}(\xi|\eta)$

Доказательство. Докажем (1). По определению для любой ограниченной f имеем:

$$\begin{aligned} \mathbb{E}[f(\zeta) \mathbb{E}(\alpha\xi + \beta\eta|\zeta)] &= \mathbb{E}[f(\zeta) (\alpha\xi + \beta\eta)] = \alpha\mathbb{E}[f(\zeta) \xi] + \beta\mathbb{E}[f(\zeta) \eta] = \\ &= \mathbb{E}[f(\zeta) (\alpha\mathbb{E}(\xi|\zeta) + \beta\mathbb{E}(\eta|\zeta))] \end{aligned}$$

Теперь взяв $f(\zeta) = \mathbb{E}(\alpha\xi + \beta\eta|\zeta) - (\alpha\mathbb{E}(\xi|\zeta) + \beta\mathbb{E}(\eta|\zeta))$, получим нужное равенство почти наверное.

Во втором, если перенести все вправо, то по сути надо доказать

$$\xi \geq 0 \Rightarrow \mathbb{E}(\xi|\eta) \geq 0$$

Возьмем функцию

$$f(\eta) = 1 - \operatorname{sgn}(\mathbb{E}(\xi|\eta)) \geq 0$$

Тогда по определению

$$\mathbb{E}[f(\eta)\mathbb{E}(\xi|\eta)] = \mathbb{E}[f(\eta)\xi] \geq 0$$

В то же время

$$\mathbb{E}[f(\eta)\mathbb{E}(\xi|\eta)] = \mathbb{E}[\mathbb{E}(\xi|\eta) - |\mathbb{E}(\xi|\eta)|] \leq 0$$

Следовательно

$$\mathbb{E}(\xi|\eta) = |\mathbb{E}(\xi|\eta)|$$

почти наверное, следовательно она почти наверное ≥ 0 .

В (3) возьмем $f(\eta) \equiv 1$ и запишем определение.

(4):

$$\mathbb{E}[f(\eta)\xi] = \mathbb{E}f(\eta)\mathbb{E}\xi = \mathbb{E}[f(\eta)\mathbb{E}\xi] \Rightarrow \mathbb{E}(\xi|\eta) = \mathbb{E}\xi$$

(5):

$$\mathbb{E}[f(\eta)\xi\zeta] = \mathbb{E}[f(\eta)\mathbb{E}(\xi\zeta|\eta)]$$

С другой стороны:

$$\begin{aligned} \mathbb{E}[f(\eta)\xi\zeta] &= \mathbb{E}[f(\eta)g(\eta)\zeta] = \mathbb{E}[f(\eta)g(\eta)\mathbb{E}(\xi|\eta)] \\ &\Rightarrow \mathbb{E}(g(\eta)\xi|\eta) = g(\eta)\mathbb{E}(\xi|\eta) \end{aligned}$$

почти наверное

■

Теорема 13. (Аналог формулы Байеса)

$$\mathbb{E}(g(\eta)|\xi = x) = \frac{\mathbb{E}[g(\eta)\rho_{\xi|\eta}(x, \eta)]}{\mathbb{E}\rho_{\xi|\eta}(x, \eta)}$$

для любой ограниченной g

Доказательство. Для любой ограниченной f :

$$\mathbb{E}[f(\xi)g(\eta)] = \mathbb{E}[g(\eta)\mathbb{E}(f(\xi)|\eta)] = \mathbb{E}\int_{-\infty}^{+\infty} f(x)\rho_{\xi|\eta}(x, \eta)g(\eta)dx = \int_{-\infty}^{+\infty} f(x)\mathbb{E}[\rho_{\xi|\eta}(x, \eta)g(\eta)]dx$$

С другой стороны

$$\mathbb{E}[f(\xi)g(\eta)] = \mathbb{E}[f(\xi)\mathbb{E}(g(\eta)|\xi)] = \int_{-\infty}^{+\infty} f(x)\rho_{\xi}(x)\mathbb{E}[g(\eta)|\xi = x]dx$$

(опять подставляя вместо f разность этих величин) получаем равенство почти наверное:

$$\mathbb{E}[\rho_{\xi|\eta}(x, \eta)g(\eta)] = \rho_{\xi}(x)\mathbb{E}[g(\eta)|\xi = x]$$

Подставим $g \equiv 1$:

$$\mathbb{E}[\rho_{\xi|\eta}(x, \eta)] = \rho_{\xi}(x)$$

В итоге получаем:

$$\mathbb{E}[g(\eta)\rho_{\xi|\eta}(x, \eta)] = \mathbb{E}[\rho_{\xi|\eta}(x, \eta)]\mathbb{E}[g(\eta)|\xi = x]$$

■

Пример 12. Пусть (ξ, η) — нормальный вектор. Посчитаем $E[\xi|\eta]$ (помним, что это как проекция ξ на η). Центрируем случайные величины

$$X := \xi - \mathbb{E}\xi$$

$$Y := \eta - \mathbb{E}\eta$$

Найдем ортогональную Z проекцию X на Y (должно быть $X = Z + \mathbb{E}[\xi|\eta]$):

$$Z = X - \frac{\text{cov}(X, Y)}{\text{cov}(Y, Y)} Y = X - \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} Y$$

Выразим ξ :

$$\xi = \mathbb{E}\xi - \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} (\eta - \mathbb{E}\eta) + Z$$

Теперь будем считать условное матожидание (условно от константы или $f(\eta)$ она сама, условное от независимой — его ожидание):

$$\mathbb{E}[\xi|\eta] = \mathbb{E}\xi - \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} (\eta - \mathbb{E}\eta) + \mathbb{E}Z = \mathbb{E}\xi - \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} (\eta - \mathbb{E}\eta)$$

Так как (Y, Z) — нормальный вектор и $\text{cov}(Y, Z) = 0$, то Y и Z независимые случайные величины. $Z \sim N\left(0, \frac{\mathbb{D}\xi\mathbb{D}\eta - [\text{cov}(\xi, \eta)]^2}{\mathbb{D}\eta}\right)$, так как это линейная комбинация случайных величин нормального вектора.

Теперь найдем условную плотность:

$$\mathbb{E}[f(X) | Y = y] = \mathbb{E}\left[f\left(Z + \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} Y\right) | Y = y\right] = \int_{-\infty}^{+\infty} f\left(z + \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} y\right) \frac{\rho_{Z,Y}(z, y)}{\rho_Y(y)} dz =$$

Совместная плотность раскладывается в произведение:

$$= \int_{-\infty}^{+\infty} f\left(z + \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} y\right) \rho_Z(z) dz =$$

Делаем замену $u = z + \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} y$:

$$= \int_{-\infty}^{+\infty} f(u) \rho_Z\left(u - \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} y\right) du$$

В итоге получаем

$$\rho_{X|Y}(x, y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \rho_Z(z)$$

, где

$$\mu = \frac{\text{cov}(\xi, \eta)}{\mathbb{D}\eta} y$$

$$\sigma = \frac{\mathbb{D}\xi\mathbb{D}\eta - [\text{cov}(\xi, \eta)]^2}{\mathbb{D}\eta}$$

Статистика

9 Оценки параметров и их свойства

Пусть есть X случайная величина. Мы знаем распределение случайной величины $F_\theta(t)$ с точностью до параметра $\theta \in \Theta$. Задача статистики заключается в том, чтобы оценить параметр θ .

Определение 11. Вектор (X_1, \dots, X_n) с независимыми компонентами, где все случайные величины $X_i \sim X$, называется *выборкой*. В теории вероятности выборка — набор случайных величин, в статистике выборка — величины, полученные в ходе эксперимента над этими случайными величинами (*простая выборка*, $(x_1, \dots, x_n) = (X_1(w), \dots, X_n(w))$).

Определение 12. Случайные величины вида $T_N(X_1, \dots, X_n)$ называются *статистиками*. Если статистика оценивает θ , то она называется оценкой. Обозначение: $\hat{\theta}_n(X_1, \dots, X_n)$

Сформулируем свойства хороших оценок:

1. **Несмещенность.** $\mathbb{E}\hat{\theta}(X_1, \dots, X_n) = \theta$. Заметим, что матожидание здесь мы считаем по распределению F_θ , то есть хочется, чтобы оценка в среднем была верна.

Пример 13. Пусть $\mathbb{E}X_i = \mu$, μ — единственный параметр. Возьмем оценку \bar{X} . Она будет несмещенной: $\mathbb{E}\bar{X} = \mu$. А если, например, параметризована дисперсия σ^2 и в качестве оценки берем смещенную выборочную дисперсию, то $\mathbb{E}s_n^2 = \frac{n}{n-1}\sigma^2 \neq \sigma^2$, получили смещенную оценку.

Пример 14. Пусть $X \sim \text{Bern}(p)$. Тогда для нахождения несмещенной статистики, надо чтобы выполнялось равенство

$$\mathbb{E}T(X_1, \dots, X_n) = \sum_{k=0}^n \left[p^k (1-p)^{n-k} \sum_{k \text{ успехов}} T(\varepsilon_1, \dots, \varepsilon_n) \right] = \theta.$$

Если мы определим $\theta = \frac{1}{p}$, то несмещенных статистик не существует. Несмещенность должна выполняться $\forall \theta$, но, если $p \rightarrow 0$, то левая часть будет стремиться к некоторой константе, а правая $\theta \rightarrow +\infty$.

Пример 15. Теперь приведем пример бессмысленной несмещенной оценки. Пусть $N = 1$, $X \sim \text{Pois}(\theta)$, где $0 < \theta < 1$. Тогда

$$\mathbb{E}T(X_1) = e^{-\theta} \sum_{k=0}^{+\infty} \frac{T(k) \theta^k}{k!} = \theta$$

$$\sum_{k=0}^{+\infty} \frac{T(k) \theta^k}{k!} = \theta e^\theta = \sum_{k=0}^{+\infty} \frac{\theta^{k+1}}{k!}$$

Приравнивая соответственные члены, получаем, что $T(k) = k$, то есть $T(X_1) = X_1$. Наша оценка никак не пересекается с множеством параметров, она бессмысленна.

2. **Состоятельность.** Оценка называется состоятельной, если $\hat{\theta}_n(X_1, \dots, X_n) \xrightarrow{P} \theta$. Это значит, на больших объемах данных мы получаем более точную оценку (ЗБЧ).

Утверждение 1. Если $\hat{\theta}_n$ — несмещенная оценка θ и $\mathbb{D}\hat{\theta}_n \rightarrow 0$, то $\hat{\theta}_n$ — состоятельная.

Доказательство. Запишем неравенство Чебышева:

$$P\left(\left|\hat{\theta} - \theta\right| \geq \varepsilon\right) \leq \frac{\mathbb{D}\hat{\theta}_n}{\varepsilon^2}$$

Все ясно. ■

Записанное неравенство наталкивает на мысль, что при маленькой дисперсии, наши оценки будут более вероятно слабо разбросаны вокруг θ .

3. **Оптимальность.** Несмещенная оценка $\hat{\theta}_n$ называется оптимальной, если $\mathbb{D}\hat{\theta}_n \leq \mathbb{D}\theta_n^*$, \forall несмещенных оценок θ_n^*

Утверждение 2. Не существует в общем случае самой оптимальной оценки в множестве всех оценок.

Доказательство. Допустим, такая оценка существует, что

$$\mathbb{E}\left[\hat{\theta}_n - \theta\right]^2 \leq \mathbb{E}\left[\theta_n^* - \theta\right]^2$$

для $\forall \theta \in \Theta$. Но если мы возьмем $\theta_n^* \equiv A$, то получим, что $\hat{\theta}_n = A$ почти наверное по распределению F_A . Теперь возьмем $\theta_n^* = B \neq A$ и получим, что $\hat{\theta}_n = B$ почти наверное по распределению F_B . Получили противоречие (противоречие получаем из-за оговорки в общем случае, что $\exists C : P_A(C), P_B(C) > 0$, то есть что распределения пересекаются, если не пересекаются, то никаких противоречий) ■

4. **Сильная состоятельность.** $\lim_{n \rightarrow +\infty} \hat{\theta}_n(X_1, \dots, X_n) = \theta$ почти наверное на распределении F_θ
5. **Асимптотическая нормальность.** Оценка называется асимптотически нормальной, если

$$\sqrt{n} \left(\hat{\theta}_n(X_1, \dots, X_n) - \theta \right) \xrightarrow{d} N(0, \sigma(\theta))$$

Это условие влечет состоятельность и позволяет оценивать вероятности событий $\alpha < \hat{\theta}_n(X_1, \dots, X_n) < \beta$ через нормальные распределения.

Предложение 11. Если оценка асимптотически нормальная, то она состоятельна.

Доказательство. $\hat{\theta}_n(X_1, \dots, X_n) - \theta \xrightarrow{d} 0$ (отсылка к первой теореме), $\theta \xrightarrow{P} \theta$
 $\Rightarrow \hat{\theta}_n(X_1, \dots, X_n) \xrightarrow{P} \theta$ (взяли сумму первых двух) ■

Предложение 12. Если эффективная оценка существует, то она единственна.

Доказательство. Пусть θ_1^* и θ_2^* две эффективные оценки. Тогда оценка $\frac{\theta_1^* + \theta_2^*}{2}$ также является несмещенной. Кроме того (пусть $\mathbb{D}\theta_1^* = \mathbb{D}\theta_2^* = a^2$),

$$\mathbb{D}\frac{\theta_1^* + \theta_2^*}{2} = \frac{1}{4}a^2 + \frac{1}{2}\text{cov}(\theta_1^*, \theta_2^*) + \frac{1}{4}a^2 \geq a^2$$

то есть $\text{cov}(\theta_1^*, \theta_2^*) \geq a^2$. Тогда получим

$$\mathbb{D}[\theta_1^* - \theta_2^*] = 2a^2 - 2\text{cov}(\theta_1^*, \theta_2^*) \leq 0$$

Иначе говоря, $\theta_1^* = \theta_2^*$ п.н. ■

10 Метод моментов

У нас есть некоторая простая выборка (x_1, \dots, x_n) , взятая из распределения F_θ , мы хотим по ней получить состоятельную оценку для θ .

Пусть g — непрерывная функция (методом моментов он называется, потому что обычно в качестве g берется степенная функция), что $\mathbb{E}_\theta |g(X)| < \infty$. Тогда введем функцию $f(\theta) := \mathbb{E}_\theta g(X)$. Матожидание является функцией от θ , потому что неизвестно нам только распределение, которое зависит от θ . Теперь допустим, что $\exists f^{-1}$ на Θ . Тогда легко найти θ :

$$\theta = f^{-1}(f(\theta)) = f^{-1}(\mathbb{E}_\theta g(X))$$

Но так как распределения мы не знаем, у нас есть только простая выборка из него, то поступаем так. Знаем, что по ЗБЧ

$$\frac{g(X_1) + \dots + g(X_n)}{n} \xrightarrow{p} \mathbb{E}_\theta g(X) = f(\theta)$$

Тогда по теоремам непрерывности (предложение 1):

$$f^{-1}\left(\frac{g(X_1) + \dots + g(X_n)}{n}\right) \xrightarrow{p} \theta$$

Тогда

$$\hat{\theta}_n(X_1, \dots, X_n) = f^{-1}\left(\frac{g(x_1) + \dots + g(x_n)}{n}\right)$$

1. Оценка получилась состоятельная.
2. Покажем асимптотическую нормальность оценки. По ЦПТ знаем, что

$$\xi_n = \sqrt{n} \left(\frac{g(X_1) + \dots + g(X_n)}{n} - \mathbb{E}_\theta g(X) \right) \xrightarrow{p} \xi \sim N(0, \mathbb{D}_\theta g(X))$$

Обозначим

$$a = \mathbb{E}_\theta g(X), \quad \sigma^2 = \mathbb{D}_\theta g(X)$$

Тогда, предполагая, что g^{-1} непрерывно дифференцируема, по теореме непрерывности (предложение 6), получаем:

$$\sqrt{n}(\hat{\theta}_n(X_1, \dots, X_n) - \theta) = \sqrt{n} \left(g^{-1} \left(a + \frac{\sigma}{\sqrt{n}} \xi_n \right) - g^{-1}(a) \right) \xrightarrow{d} \xi (h^{-1})'(a)$$

То есть, если $(h^{-1})'(a) \neq 0$, то оценка $\hat{\theta}_n(X_1, \dots, X_n)$ асимптотически нормальна с коэффициентом $\sigma(\theta) = (h'(a))^2 \sigma^2$

Пример 16. Возьмем выборку (X_1, \dots, X_n) из равномерного распределения $U_{[0, \theta]}$, где $\theta > 0$. Найдём оценку по методу моментов при $f(x) = x$:

$$\mathbb{E}_\theta f(X) = \frac{\theta}{2} \Rightarrow \theta = 2\mathbb{E}_\theta f(X)$$

Получаем оценку

$$\hat{\theta}_n = 2\bar{X}$$

11 Информация Фишера и неравенство Рао-Крамера

Определение 13. Несмещенной оценкой нуля называется такая статистика, $U(X_1, \dots, X_n)$, для которой верно $\mathbb{E}_\theta U = 0, \forall \theta$ (можно опять провести аналогии со скалярным произведением)

Утверждение 3. $\hat{\theta}$ — оптимальная (минимальная по дисперсии) $\Leftrightarrow \mathbb{E}[\hat{\theta}U] = 0 \forall U$ — несмещенных оценок нуля.

Доказательство. \Rightarrow

Заметим, что $\forall \lambda$ верно $\mathbb{E}(\hat{\theta} + \lambda U) = \hat{\theta}$ и из оптимальности $\mathbb{D}\hat{\theta} \leq \mathbb{D}(\hat{\theta} + \lambda U)$. Раскрыв дисперсию, получим

$$\begin{aligned}\mathbb{D}\hat{\theta} &\leq \mathbb{D}\hat{\theta} + \lambda^2 \mathbb{D}U + 2\lambda \text{cov}(\hat{\theta}, U) \\ 2\lambda \text{cov}(\hat{\theta}, U) + \lambda^2 \mathbb{D}U &\geq 0\end{aligned}$$

Это верно только, когда $\text{cov}(\hat{\theta}, U) = 0$ (потому что иначе есть λ , в которых неравенство не выполняется). Осталось записать

$$\text{cov}(\hat{\theta}, U) = \mathbb{E}[(\hat{\theta} - \theta)U] = \mathbb{E}[\hat{\theta}U] = 0$$

\Leftarrow

Возьмем другую несмещенную оценку $\tilde{\theta}$. Рассмотрим ее дисперсию:

$$\mathbb{D}\tilde{\theta} = \mathbb{E}(\tilde{\theta} - \theta)^2 = \mathbb{E}((\tilde{\theta} - \hat{\theta}) + (\hat{\theta} - \theta))^2 = \mathbb{E}(\tilde{\theta} - \hat{\theta})^2 + 2\mathbb{E}[(\tilde{\theta} - \hat{\theta})(\hat{\theta} - \theta)] + \mathbb{E}(\hat{\theta} - \theta)^2$$

Заметим, что

$$\mathbb{E}[(\tilde{\theta} - \hat{\theta})(\hat{\theta} - \theta)] = \mathbb{E}[(\tilde{\theta} - \hat{\theta})\hat{\theta}] = 0$$

Последнее равенство вытекает, из условия, если взять $U = \tilde{\theta} - \hat{\theta}$. Тогда получаем, что

$$\mathbb{D}\tilde{\theta} = \mathbb{D}\hat{\theta} + \mathbb{D}(\tilde{\theta} - \hat{\theta}) \geq \mathbb{D}\hat{\theta}$$

То есть $\hat{\theta}$ оптимальна. ■

Пример 17. Пусть $X \sim \text{Bern}(\theta)$. Рассмотрим оценку \bar{X} . Она несмещенная и по ЗБЧ состоятельная. Докажем оптимальность. По доказанному утверждению, нужно убедиться, что $\mathbb{E}\bar{X}U = 0 \forall U$ — несмещенных оценок нуля. Запишем $\forall \theta$

$$0 = \mathbb{E}U(X_1, \dots, X_n) = \sum_{\varepsilon_i \in \{0,1\}} U(\varepsilon_1, \dots, \varepsilon_n) \theta^{\sum \varepsilon_i} (1 - \theta)^{n - \sum \varepsilon_i} =$$

Сгруппируем

$$= \sum_{k=0}^n \left[\theta^k (1 - \theta)^{n-k} \sum_{\varepsilon_i: \sum \varepsilon_i = k} U(\varepsilon_1, \dots, \varepsilon_n) \right] = \sum_{k=0}^n \theta^k (1 - \theta)^{n-k} Q_k = \frac{1}{\theta^n} \sum_{k=0}^n \left(\frac{\theta}{1 - \theta} \right)^k Q_k = 0$$

При $\theta \in (0, 1)$, $\frac{\theta}{1 - \theta} \in (0, +\infty)$ — на этом промежутке многочлен равен нулю, тогда получается, что $Q_k = 0$. Теперь можем проверить \bar{X} на оптимальность:

$$\mathbb{E}\bar{X}U = \sum_{k=0}^n \left[\frac{k}{n} \sum_{\varepsilon_i: \sum \varepsilon_i = k} U(\varepsilon_1, \dots, \varepsilon_n) \theta^k (1 - \theta)^{n-k} \right] = \sum_{k=0}^n \frac{k}{n} Q_k \theta^k (1 - \theta)^{n-k} = 0$$

Получили оптимальность \bar{X} .

В методе максимального правдоподобия мы более подробно разберем понятие информации, а пока обойдемся сухими определениями.

Определение 14. Пусть $X = (X_1, \dots, X_n)$ простая выборка из распределения с плотностью ρ_θ , тогда функция $p(x, \theta) = \rho_\theta(x_1) \cdots \rho_\theta(x_n)$ называется *функцией правдоподобия*, однако с произведением работать неудобно, поэтому прологарифмируем: $L(x, \theta) = \sum_{j=1}^n \ln \rho_\theta(x_j)$

Определение 15. Величина $I(\theta) = \mathbb{E}_\theta \left[\frac{\partial L}{\partial \theta} \right]^2$ называется *информацией Фишера*.

В дальнейших рассуждениях предполагается выполнение условий регулярности для функции правдоподобия, что она непрерывна и дифференцируема по θ и что операции дифференцирования и интегрирования перестановочны $\left(\int f' dx = \left(\int f dx \right)' \right)$

Предложение 13. (аддитивность информации Фишера) Верно равенство

$$I(\theta) = ni(\theta),$$

где $i(\theta)$ — информация Фишера для выборки из одного элемента.

Доказательство. Заметим, что

$$\mathbb{E} \frac{\partial L}{\partial \theta} = \mathbb{E} \left[\sum_{j=1}^n \frac{\rho'_\theta(x_j)}{\rho_\theta(x_j)} \right] = \sum_{j=1}^n \int \frac{\rho'_\theta(x_j)}{\rho_\theta(x_j)} \rho_\theta(x_j) dx = \sum_{j=1}^n \left(\int_{-\infty}^{+\infty} \rho_\theta(x_j) dx \right)' = \sum_{j=1}^n (1)' = 0$$

Поэтому

$$I(\theta) = \mathbb{E} \left[\frac{\partial L}{\partial \theta} \right]^2 = \mathbb{D} \left[\frac{\partial L}{\partial \theta} \right] = \mathbb{D} \left[\sum_{j=1}^n \frac{\rho'_\theta(x_j)}{\rho_\theta(x_j)} \right] = \sum_{j=1}^n \mathbb{D} \left[\frac{\rho'_\theta(x_j)}{\rho_\theta(x_j)} \right] = \sum_{j=1}^n i(\theta) = ni(\theta)$$

■

Рассмотрим неравенство, позволяющее оценивать оптимальные оценки.

Теорема 14. (неравенство Рао-Крамера) Выполняются условия регулярности и $I(\theta) > 0$ (если $= 0$, то это значит, что мы от эксперимента не получаем никакой информации и все бессмысленно). Пусть $\theta_n(X)$ — произвольная несмещенная оценка статистика $\tau(\theta)$. Тогда верно

$$\mathbb{D}\theta_n(X) \geq \frac{(\tau'(\theta))^2}{I(\theta)}$$

Доказательство. Из несмещенности знаем

$$\mathbb{E}\theta_n(X) = \int \theta_n(x_1, \dots, x_n) p(x_1, \dots, x_n, \theta) dx_1 \cdots dx_n = \tau(\theta) = A$$

Также знаем

$$\int p(x_1, \dots, x_n, \theta) dx_1 \cdots dx_n = 1 = B$$

Рассмотрим выражение $A'_\theta - \theta B'_\theta (= \tau'(\theta))$ по понятным причинам):

$$\tau'(\theta) = \int (\theta_n(x) - \theta) p'(x, \theta) dx = \int (\theta_n(x) - \theta) \frac{p'(x, \theta)}{p(x, \theta)} p(x, \theta) dx = \mathbb{E} \left[(\theta_n - \theta) \frac{\partial L}{\partial \theta} \right]$$

Из неравенства Коши-Буняковского получим:

$$\tau'(\theta) = \mathbb{E} \left[(\theta_n - \theta) \frac{\partial L}{\partial \theta} \right] \leq \sqrt{\mathbb{D}\theta_n} \sqrt{\mathbb{E} \left[\frac{\partial L}{\partial \theta} \right]^2}$$

$$(\tau'(\theta))^2 \leq I(\theta) \mathbb{D}\theta_n$$

■

Замечание 1. Можно переписать неравенство в виде

$$\mathbb{D}\theta_n \leq \frac{(\tau'(\theta))^2}{ni(\theta)}$$

То есть как бы мы не старались, точность оценки будет порядка $\frac{1}{n}$.

12 Метод максимального правдоподобия

Во-первых рассмотрим пример, объясняющий понятие информации.

Пример 18. Пусть есть монетка M с $P(M = 0) = q$, $P(M = 1) = p$. Подбрасывается монетка, и, в зависимости от исхода, генерируется случайное событие из распределение ρ_0 или ρ_1 . Таким образом, получили случайную величину ξ . Изначально шансы, что случайная величина была взята из первого распределения против нулевого $\frac{p}{q}$. Несложно вычислить шансы после одной генерации случайного события. Воспользовавшись аналогом формулы Байеса, получим

$$P(M = 1|\xi = x) = \frac{\rho_1(x)p}{\rho_1(x)p + \rho_0(x)q}, \quad P(M = 0|\xi = x) = \frac{\rho_0(x)q}{\rho_1(x)p + \rho_0(x)q}$$

То есть теперь шансы $\frac{\rho_1(x)p}{\rho_0(x)q}$. Они изменились. Пусть *информация* – это то, как изменились шансы. Как можно измерить информацию, полученную в ходе эксперимента? Например, возьмем разницу \ln от шансов:

$$\ln \frac{\rho_1(x)p}{\rho_0(x)q} - \ln \frac{p}{q} = \ln \frac{\rho_1(x)}{\rho_0(x)}$$

Ну и чтобы для каждой величины не вычислять выражение, усредним по распределению ρ_1 (можно было и по ρ_0 усреднять) и будем называть это выражение информацией:

$$\tilde{I} = \int \ln \frac{\rho_1(x)}{\rho_0(x)} \rho_1(x) dx = \int \ln \rho_1(x) \rho_1(x) dx - \int \ln \rho_0(x) \rho_1(x) dx$$

Утверждение 4. (*неравенство информации*) Пусть ρ_0, ρ_1 – вероятностные плотности. Тогда

$$\int \ln \rho_1(x) \rho_1(x) dx \geq \int \ln \rho_0(x) \rho_1(x) dx,$$

то есть $\tilde{I} \geq 0$. Причем равенство выполняется $\Leftrightarrow \rho_0 \equiv \rho_1$

Доказательство. Хотим доказать

$$\int \ln \frac{\rho_0(x)}{\rho_1(x)} \rho_1(x) dx \leq 0$$

Знаем, что $\ln x \leq x - 1$. Тогда

$$\ln \frac{\rho_0(x)}{\rho_1(x)} \rho_1(x) \leq \rho_0(x) - \rho_1(x)$$

Подставляя в интеграл, получим, что

$$\int \ln \frac{\rho_0(x)}{\rho_1(x)} \rho_1(x) dx \leq 1 - 1 = 0$$

Теперь посмотрим, когда выполняется равенство. Оно выполняется, когда $\ln x = x - 1$, то есть

$$\int \left(\frac{\rho_0(x)}{\rho_1(x)} - 1 + \ln \frac{\rho_0(x)}{\rho_1(x)} \right) \rho_1(x) dx = 0$$

Тогда

$$\frac{\rho_0(x)}{\rho_1(x)} - 1 + \ln \frac{\rho_0(x)}{\rho_1(x)} = 0$$

почти наверное (так как это выражение ≥ 0), то есть $\rho_0 = \rho_1$ почти наверное. ■

То есть, если $\tilde{I} = 0$, то от новой информации ничего не меняется, она бессмысленна. Также добавим, что \tilde{I} в реальности оценивает расстояние между распределениями, это называется энтропией распределения ρ_1 относительно ρ_0 .

Применим полученные знания для построения оценки. Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения с параметром $\theta = \theta_1$. Рассмотрим функцию $W(\theta) = \mathbb{E}_{\theta_1} \ln \rho_\theta(X_1)$, ее называют истинным правдоподобием. Заметим из неравенства информации, что максимум истинного правдоподобия достигается только на $\theta = \theta_1$. Само матожидание вычислять мы не умеем, но по ЗБЧ значим, что

$$\frac{1}{n} L(X, \theta) = \frac{1}{n} \sum \ln \rho_\theta(x_j) \xrightarrow{P} W(\theta)$$

Тогда *оценкой максимального правдоподобия* называется оценка $\hat{\theta} = \operatorname{argmax}_\theta L(X, \theta)$. Если посмотреть, что мы максимизируем функцию L , и вспомнить, что это по сути функция правдоподобия, то выходит, что мы максимизируем вероятность получения выборки X из распределения с параметром $\hat{\theta}$. Еще заметим, что $W(\theta_1) - W(\theta)$ это величина из примера с монетой, то есть количество информации, которое дало одно наблюдение.

Утверждение 5. (*состоятельность оценки методом максимального правдоподобия*) Дана выборка $X = (X_1, \dots, X_n)$. Пусть $\theta \in (\alpha, \beta)$ и на этом промежутке у функции $L(X_1, \dots, X_n, \theta)$ $\exists \hat{\theta}_n$ – точка локального максимума, тогда $\hat{\theta}_n \xrightarrow{P} \theta_1$, то есть оценка состоятельна.

Доказательство. По ЗБЧ $\frac{1}{n} L(X, \theta) \xrightarrow{P} W(\theta)$. Хотим $\forall \delta > 0: \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \delta) = 0$. Из информационного неравенства заметим, что $W(\theta_1 - \delta) < W(\theta_1) < W(\theta_1 + \delta)$. Знаем, что $\frac{1}{n} L(X, \theta_1 - \delta)$, $\frac{1}{n} L(X, \theta_1)$, $\frac{1}{n} L(X, \theta_1 + \delta)$ сходятся по вероятности соответственно к $W(\theta_1 - \delta)$, $W(\theta_1)$, $W(\theta_1 + \delta)$. Докажем, что сохраняются те же знаки неравенства.

Пусть $\varepsilon = W(\theta_1) - W(\theta_1 - \delta) > 0$. Знаем, что

$$P\left(\left|\frac{1}{n} L(X, \theta_1 - \delta) - W(\theta_1 - \delta)\right| \geq \frac{\varepsilon}{10}\right) \xrightarrow{n \rightarrow \infty} 0$$

$$P\left(\left|\frac{1}{n} L(X, \theta_1) - W(\theta_1)\right| \geq \frac{\varepsilon}{10}\right) \xrightarrow{n \rightarrow \infty} 0$$

Тогда

$$\begin{aligned} & P\left(\frac{1}{n} L(X, \theta_1 - \delta) \geq \frac{1}{n} L(X, \theta_1)\right) \leq \\ & \leq P\left(\left\{\left|\frac{1}{n} L(X, \theta_1 - \delta) - W(\theta_1 - \delta)\right| \geq \frac{\varepsilon}{10}\right\} \cup \left\{\left|\frac{1}{n} L(X, \theta_1) - W(\theta_1)\right| \geq \frac{\varepsilon}{10}\right\}\right) \leq \\ & \leq P\left(\left|\frac{1}{n} L(X, \theta_1 - \delta) - W(\theta_1 - \delta)\right| \geq \frac{\varepsilon}{10}\right) + P\left(\left|\frac{1}{n} L(X, \theta_1) - W(\theta_1)\right| \geq \frac{\varepsilon}{10}\right) \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

Допустим противное, что в первом неравенстве может стоять $< \frac{\varepsilon}{10}$ в обоих случаях. Тогда выходит

$$\varepsilon = W(\theta_1) - W(\theta_1 - \delta) \leq \frac{1}{n} L(X, \theta_1) + \frac{\varepsilon}{10} - W(\theta_1 - \delta) \leq \frac{1}{n} L(X, \theta_1) + \frac{\varepsilon}{10} - \frac{1}{n} L(X, \theta_1 - \delta) + \frac{\varepsilon}{10} \leq \frac{\varepsilon}{5}$$

Получили противоречие, то есть все ок. То есть вышло, что $\frac{1}{n} L(X, \theta_1 - \delta) < \frac{1}{n} L(X, \theta_1)$ почти наверное. Второе неравенство доказывается аналогично.

Получив желаемые неравенства, делаем вывод, что внутри отрезка $[\theta_1 - \delta, \theta_1 + \delta]$ есть локальный максимум, то есть $|\hat{\theta}_n - \theta_1| < \delta$ (строгое неравенство, потому что мы доказывали строгие неравенства для L)

■

Замечание 2. Теперь обсудим, откуда возникает информация Фишера. У нас есть функция истинного правдоподобия $W(\theta)$. Разложим ее по Тейлору в точке θ_1 (предполагаем, что зависимость от θ позволяет дифференцировать под знаком интеграла). $W'(\theta) = \int \frac{\rho'_\theta(x)}{\rho_\theta(x)} \rho_{\theta_1}(x) dx$,

соответственно $W'(\theta_1) = 0$. $W''(\theta) = \int \frac{\rho''_\theta(x)}{\rho_\theta(x)} \rho_{\theta_1}(x) dx - \int \left(\frac{\rho'_\theta(x)}{\rho_\theta(x)} \right)^2 \rho_{\theta_1}(x) dx$, соответственно

$W''(\theta_1) = 0 - \int \left(\frac{\partial \ln \rho_\theta(x)}{\partial \theta} \right)^2 \rho_{\theta_1}(x) dx = -I(\theta_1)$. В итоге получаем:

$$W(\theta) \approx W(\theta_1) - \frac{1}{2} I(\theta_1) (\theta - \theta_1)^2$$

То есть она выражает скорость изменения информации в окрестности максимума θ_1 .

Замечание 3. Теперь вспомним неравенство Рао-Крамера. Равенство в неравенстве Коши-Буняковского выполняется только в случае пропорциональности $\theta_n(X) - \tau(\theta)$ и $\frac{\partial L}{\partial \theta}$. То есть, когда

$$\theta_n(X) - \tau(\theta) = C(\theta) \frac{\partial L}{\partial \theta}$$

Это знание в некоторых случаях помогает находить эффективные оценки

Замечание 4. Также отметим, что если существует несмещенная оценка $\theta_n(X)$ параметра θ , на которой достигается равенство в Рао-Крамере, то это обязательно оценка максимального правдоподобия. Действительно, верно равенство

$$\theta_n(X) - \tau(\theta) = C(\theta) \frac{\partial L}{\partial \theta}$$

Подставив вместо θ оценку максимального правдоподобия, получим

$$\theta_n(X) - \hat{\theta}_n(X) = 0$$

То есть они равны.

Замечание 5. И, наконец, сделаем небольшое замечание о том, откуда берется асимптотическая нормальность оценки максимального правдоподобия. Разложим $\frac{\partial L}{\partial \theta}(X, \theta)$ по Тейлору в θ_1 (примерно, без о малых):

$$\frac{\partial L}{\partial \theta}(X, \theta) \approx \frac{\partial L}{\partial \theta}(X, \theta_1) + \frac{\partial^2 L}{\partial \theta^2}(X, \theta_1) (\theta - \theta_1)$$

Если мы подставим $\theta = \hat{\theta}_n(X)$ — оценку максимального правдоподобия, то $\frac{\partial L}{\partial \theta}(X, \hat{\theta}_n(X)) = 0$ просто из определения оценки максимального правдоподобия. Тогда получаем:

$$\hat{\theta}_n - \theta_1 = - \frac{\frac{\partial L}{\partial \theta}}{\frac{\partial^2 L}{\partial \theta^2}}$$

Домножим на \sqrt{n} , чтобы стало как в ЦПТ. Берем $\frac{\partial L}{\partial \theta} = \frac{1}{n} \sum_{j=1}^n \frac{\partial}{\partial \theta} \ln \rho_{\theta_1}(x_j)$. Помним, что $\mathbb{E} \frac{\partial}{\partial \theta} \ln \rho_{\theta_1}(x_j) = 0 = \mu$. Теперь дисперсия:

$$\sigma^2 = \mathbb{D} \frac{\partial}{\partial \theta} \ln \rho_{\theta_1}(x_j) = \mathbb{E} \left[\frac{\partial}{\partial \theta} \ln \rho_{\theta_1}(x_j) \right]^2 = I(\theta_1)$$

Тогда из ЦПТ получаем

$$\frac{\partial L}{\partial \theta} \xrightarrow{P} N(0, I(\theta_1))$$

Теперь разберемся с

$$\frac{\partial^2 L}{\partial \theta^2} = \frac{1}{n} \sum_{j=1}^n \frac{\partial^2}{\partial \theta^2} \ln \rho_{\theta_1}(x_j) \xrightarrow{P} -I(\theta_1)$$

То есть $\mathbb{E} \frac{\partial^2 L}{\partial \theta^2} = -I(\theta_1)$. В итоге получаем, что $\sqrt{n}(\hat{\theta}_n - \theta_1) \xrightarrow{P} N\left(0, \frac{1}{I(\theta_1)}\right)$

13 Доверительные интервалы

Ясно, что информации о состоятельности оценки $\hat{\theta}_n(X)$ не достаточно для того, чтобы что-то говорить о возможном значении θ . Предположим, что мы знаем “скорость сходимости”, то есть для фиксированного $\alpha \in (0, 1)$, для фиксированного $\varepsilon > 0$ мы можем подобрать такой номер n , начиная с которого $P_\theta \left(\left| \hat{\theta}_n(X) - \theta \right| < \varepsilon \right) > 1 - \alpha$. Тогда параметр θ с большой вероятностью $\theta \in \left(\hat{\theta}_n(X) - \varepsilon, \hat{\theta}_n(X) + \varepsilon \right)$.

Определение 16. Обобщая данное наблюдение, приходим к следующей конструкции. Пусть заданы две статистики $\theta_1(X)$ и $\theta_2(X)$. Случайный интервал $(\theta_1(X), \theta_2(X))$ называется *доверительным интервалом* с уровнем доверия $1 - \alpha$, если при всех θ верно

$$P(\theta_1(X) < \theta < \theta_2(X)) \geq 1 - \alpha$$

Если же задана последовательность пар статистик $\theta_1^n(X)$ и $\theta_2^n(X)$, для которой

$$\lim_{n \rightarrow \infty} \inf P(\theta_1^n(X) < \theta < \theta_2^n(X)) \geq 1 - \alpha$$

то говорят, что задан *асимптотический доверительный интервал* уровня доверия $1 - \alpha$.

Пример 19. Пусть задана выборка X_1, \dots, X_n из распределения $N(\theta, 1)$. Рассмотрим статистику \bar{X}_n , тогда $\sqrt{n}(\bar{X}_n - \theta) \sim N(0, 1)$. Пусть число z_γ выбрано так, что $\Phi(z_\gamma) = \gamma$, — квантиль нормального распределения. Тогда

$$P_\theta(z_{\alpha/2} < \sqrt{n}(\bar{X}_n - \theta) < z_{1-\alpha/2}) = 1 - \alpha$$

Так как $z_{-\alpha/2} = -z_{1-\alpha/2}$, то перепишем

$$P_\theta\left(\bar{X}_n - \frac{z_{1-\alpha/2}}{\sqrt{n}} < \theta < \bar{X}_n + \frac{z_{1-\alpha/2}}{\sqrt{n}}\right) = 1 - \alpha$$

Получили доверительный интервал. Заметим, что так как он симметричный, то он минимальный по длине среди всех доверительных интервалов такого же уровня доверия (надо было найти в стандартном распределении интервал, содержащий вероятность $1 - \alpha$, смотрим на график плотности и все понимаем).

Для построения доверительных интервалов бывает полезным использовать неравенство Чебышева или Чернова (Хефдинга-Чернова).

Пример 20. Пусть X_1, \dots, X_n выборка из распределения Бернулли с вероятностью успеха θ . По неравенству Хефдинга-Чернова

$$P(|\bar{X}_n - \theta| \geq t) \leq 2e^{-\frac{nt^2}{4}}$$

Взяв t так, чтобы $e^{-\frac{nt^2}{4}} = \frac{\alpha}{2}$, получаем доверительный интервал

$$\left(\bar{X}_n - \frac{2\sqrt{-\ln(\alpha/2)}}{\sqrt{n}}, \bar{X}_n + \frac{2\sqrt{-\ln(\alpha/2)}}{\sqrt{n}}\right)$$

Рассмотрим общий метод построения доверительных интервалов с помощью центральных статистик.

Определение 17. Статистика $V(X, \theta)$ называется *центральной*, если ее распределение зависит от θ при фиксированном X и при фиксированном X эта функция монотонна (по θ).

Тогда в силу независимости распределения от параметра θ , подберем такие v_1, v_2 , что

$$P_{\theta}(v_1 < V(X, \theta) < v_2) = 1 - \alpha$$

В силу монотонности (берем обратную функцию с сохранением всех неравенств), получаем доверительный интервал

$$P_{\theta}(V^{-1}(v_1) < \theta < V^{-1}(v_2)) = 1 - \alpha$$

Пример 21. Пусть X_1, \dots, X_n — выборка из $U[0, \theta]$. Тогда $\theta^{-1}X_j \sim U[0, 1]$. Рассмотрим статистику $V(X, \theta) = \theta^{-1}X_{(n)}$, тогда $F_{\theta^{-1}X_{(n)}}(t) = t^n$ при $t \in [0, 1]$ и

$$1 - \alpha = P(\alpha^{1/n} < V(X, \theta) < 1) = P(X_{(n)} < \theta < \alpha^{-1/n}X_{(n)})$$

Заметим, что длина доверительного интервала пропорциональна $\alpha^{-1/n} - 1 = O\left(\frac{1}{n}\right)$, то есть с ростом размера выборки, точность интервала также увеличивается.

В качестве V бывает полезным взять $\sum_{j=1}^n \ln F_{\theta}(X_j)$.

Пример 22. Рассмотрим типичный пример **посторения асимптотического доверительного интервала**. Пусть $\theta_n(X)$ асимптотически нормальная оценка параметра θ с асимптотической дисперсией $\sigma(\theta)$, то есть

$$\sqrt{n} \frac{\theta_n(X) - \theta}{\sigma(\theta)} \xrightarrow{d} N(0, 1)$$

Тогда аналогично 19 примеру, подбираем границы $z_{1-\alpha/2}$ и $z_{\alpha/2}$ (напомню, что $\Phi(z_{1-\alpha/2}) = 1 - \alpha/2$)

$$P\left(z_{\alpha/2} < \sqrt{n} \frac{\theta_n(X) - \theta}{\sigma(\theta)} < z_{1-\alpha/2}\right) \xrightarrow{n \rightarrow \infty} 1 - \alpha$$

$$P\left(\theta_n(X) - \frac{\sigma(\theta) z_{1-\alpha/2}}{\sqrt{n}} < \theta < \theta_n(X) + \frac{\sigma(\theta) z_{1-\alpha/2}}{\sqrt{n}}\right) \xrightarrow{n \rightarrow \infty} 1 - \alpha$$

Для получения доверительного интервала осталось только избавиться от $\sigma(\theta)$. Понятно, что ее можно заменить любой состоятельной оценкой (чтобы оставалась сходимости по распределению к $N(0, 1)$), например, выборочной дисперсией или $\sigma(\theta_n(X))$.

Рассмотрим теперь подробнее построение доверительных интервалов для **параметров μ и σ нормального распределения $N(\mu, \sigma)$** .

σ известна, оцениваем μ . σ может быть известна, например, если при замерах мы пользуемся прибором с известной точностью. Пусть X_1, \dots, X_n — выборка из $N(\mu, \sigma)$. Тогда

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \sim N(0, 1)$$

Аналогично прошлому примеру, получаем доверительный интервал уровня доверия $1 - \alpha$ вида

$$\left(\bar{X}_n - \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}}, \bar{X}_n + \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}}\right)$$

σ неизвестна, оцениваем μ . Пусть X_1, \dots, X_n — выборка из $N(\mu, \sigma)$. Мы знаем (см. пример 10), что выборочное среднее \bar{X}_n и выборочная дисперсия

$$S_n^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X}_n)^2$$

независимы, причем $(n-1)\sigma^2 S_n^2$ имеет хи квадрат распределение с $n-1$ степенью свободы χ_{n-1}^2 . Напомним, что

$$\rho_{\chi_n^2}(t) = C_n t^{\frac{n-2}{2}} e^{-\frac{t}{2}} \text{Ind}_{t>0}$$

Рассмотрим статистику

$$T_{n-1}(X) = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sqrt{S_n^2}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\frac{\sigma}{\sqrt{\sigma^{-2} S_n^2}}} = \frac{Z_n}{\sqrt{R_n}},$$

где $Z_n \sim N(0, 1)$, $R_n \sim \frac{1}{n-1} \chi_{n-1}^2$ и Z_n и R_n независимы. Распределение T_{n-1} имеет плотность

$$\rho(t) = C_n \left(1 + \frac{t^2}{n-1}\right)^{-n/2}$$

и называется распределением Стьюдента с $n-1$ степенью свободы. Получаем, что доверительный интервал уровня доверия $1 - \alpha$ имеет вид

$$\left(\bar{X}_n - \frac{\sqrt{S_n^2} t_{1-\alpha/2}}{\sqrt{n}}, \bar{X}_n + \frac{\sqrt{S_n^2} t_{1-\alpha/2}}{\sqrt{n}} \right), F_{T_{n-1}}(t_{1-\alpha/2}) = 1 - \alpha/2$$

Доверительный интервал для σ строится с помощью центральной статистики

$$\sigma^{-2} (n-1) S_n^2 \sim \chi_{n-1}^2$$

Пусть $F_{\chi^2}(x_{\alpha/2}) = \alpha/2$ и $F_{\chi^2}(x_{1-\alpha/2}) = 1 - \alpha/2$. Тогда

$$P\left(x_{\alpha/2} < \frac{(n-1) S_n^2}{\sigma^2} < x_{1-\alpha/2}\right) = 1 - \alpha$$

Доверительный интервал уровня доверия $1 - \alpha$ имеет вид

$$\left(\sqrt{\frac{(n-1) S_n^2}{x_{1-\alpha/2}}}, \sqrt{\frac{(n-1) S_n^2}{x_{\alpha/2}}} \right)$$

14 Проверка гипотез. Критерий Неймана-Пирсона

Пусть есть выборка $X = (X_1, \dots, X_n)$ из параметрического семейства с параметром θ . Какое-либо предположение о параметре θ называется *статистической гипотезой*. Статистическая гипотеза называется простой, если предположение заключается в том, что $\theta = \theta_0$ (то есть мы по выборке предлагаем конкретную оценку для θ). Наша цель состоит в построении статистического критерия, который по выборке принимает или отклоняет гипотезу H_0 (проверка гипотез). Идея построения критерия заключается в том, что получение маловероятных по H_0 значений выборки свидетельствуют против нее (например, если все значения выборки получились маловероятными, то, скорее всего, с нашей гипотезой что-то не так). Обычно критерий строится с помощью *критического множества* K — такое множество в области значений выборки, что при выполнении гипотезы H_0 вероятность попадания в это множество мала. Если $X \in K$, то гипотеза H_0 отклоняется и принимается в ином случае.

Обычно вместе с основной гипотезой H_0 задана еще и альтернативная гипотеза H_1 . При таком подходе можно совершить ошибки двух видов:

1. *Ошибка первого рода*. Когда мы отклоняем истинную гипотезу H_0 . Вероятность такой ошибки называется *уровнем значимости критерия*;
2. *Ошибка второго рода*. Когда мы принимаем ложную гипотезу H_0 , то есть принимаем H_0 при истинности H_1 ;

В случае простых гипотез ($H_0 : \theta = \theta_0$ и $H_1 : \theta = \theta_1$) вероятность ошибки первого рода $\alpha = P_{\theta_0}(X \in K)$, а вероятность ошибки второго рода $\beta = P_{\theta_1}(X \notin K)$. Величину $1 - \beta$ называют *мощностью критерия* (хочется мощность иметь побольше).

Функцию $W(K, \theta) = P_{\theta}(X \in K)$ называют функцией мощности критерия K . Обычно задача ставится следующим образом. При фиксированном уровне значимости α (то есть $W(K, \theta) \leq \alpha$ для всех θ удовлетворяющих гипотезе H_0) найти критерий наибольшей мощности (то есть $W(K, \theta) \geq W(S, \theta)$ для всех θ удовлетворяющих гипотезе H_1 , для каждого другого критерия S уровня значимости α). То есть при фиксированном уровне ошибки первого рода минимизируем ошибку второго рода.

Пример 23. Пусть $X = (X_1, \dots, X_n)$ — выборка из $N(\mu, \sigma^2)$. Предположим, мы хотим проверить гипотезу H_0 , утверждающую, что $\mu = \mu_0$, против альтернативной гипотезы $H_1: \mu = \mu_1$. Ранее мы строили для μ доверительный интервал уровня $1 - \alpha$:

$$P_{\mu} \left(\bar{X}_n - \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \leq \mu \leq \bar{X}_n + \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \right) = 1 - \alpha$$

Построим критерий на основе доверительного интервала:

$$K = \left\{ X : \bar{X}_n > \mu_0 + \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \right\} \cup \left\{ X : \bar{X}_n < \mu_0 - \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \right\}$$

Получаем уровень значимости α . Мощность критерия равна $1 - \beta$, где β — вероятность того, что μ_0 принадлежит указанному доверительному интервалу при условии $\mu = \mu_1$. Вычислим β :

$$\begin{aligned} \beta &= P_{\mu_1} \left(\bar{X}_n - \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \leq \mu_0 \leq \bar{X}_n + \frac{\sigma z_{1-\alpha/2}}{\sqrt{n}} \right) = \\ &= P_{\mu_1} \left(\frac{\sqrt{n}(\mu_0 - \mu_1)}{\sigma} - z_{1-\frac{\alpha}{2}} \leq \frac{\sqrt{n}(\bar{X}_n - \mu_1)}{\sigma} \leq \frac{\sqrt{n}(\mu_0 - \mu_1)}{\sigma} + z_{1-\frac{\alpha}{2}} \right) = \end{aligned}$$

$$= \Phi \left(\frac{\sqrt{n}(\mu_0 - \mu_1)}{\sigma} + z_{1-\frac{\alpha}{2}} \right) - \Phi \left(\frac{\sqrt{n}(\mu_0 - \mu_1)}{\sigma} - z_{1-\frac{\alpha}{2}} \right)$$

Заметим, что вероятность ошибки второго рода стремится к нулю (мощность критерия к единице) при $n \rightarrow \infty$.

Если с ростом объема выборки величина $1 - \beta$ стремится к единице, то критерий называется *состоятельным*.

Пусть H_0 состоит в том, что выборка $X = (X_1, \dots, X_n)$ имеет плотность распределения f_0 , а альтернативная гипотеза H_1 состоит в том, что выборка имеет плотность распределения f_1 . Предположим, что f_0 и f_1 положительны на \mathbb{R}^n . Рассмотрим набор множеств

$$K_t = \left\{ x \in \mathbb{R}^n : \frac{f_1(x)}{f_0(x)} \geq t \right\}, \quad t \geq 0$$

Заметим, что $P_0(X \in K) = \int_K f_0$, а $P_1(X \in K) = \int_K f_1$, то есть мы строим такое критическое множество, чтобы ошибка первого рода была поменьше, а второго побольше. Предположим, что для всякого $\alpha \in (0, 1)$ существует $t(\alpha) \geq 0$ такое, что $P_0(X \in K_{t(\alpha)}) = \alpha$.

Теорема 15. (Неймана-Пирсона)

Наиболее мощный критерий уровня значимости α задается критическим множеством $K = K_{t(\alpha)}$

Доказательство. Рассмотрим другой критерий Q уровня значимости $P_0(X \in Q) \leq \alpha = P(X \in K)$. Сравним мощности этих критериев:

$$P_1(X \in K) - P_1(X \in Q) = \int_K f_1(x) dx - \int_Q f_1(x) dx = \int_{K \setminus Q} f_1(x) dx - \int_{Q \setminus K} f_1(x) dx \geq$$

Так как $t(\alpha) f_0(x) \leq f_1(x)$ для $x \in K_{t(\alpha)}$, и $t(\alpha) f_0(x) \geq f_1(x)$ для $x \notin K_{t(\alpha)}$, то

$$\geq t(\alpha) \int_{K \setminus Q} f_1(x) dx - t(\alpha) \int_{Q \setminus K} f_1(x) dx = t(\alpha) (P_0(X \in K) - P_0(X \in Q)) \geq 0$$

■

Пример 24. Пусть $X = (X_1, \dots, X_n)$ выборка из $N(\theta, 1)$. Гипотеза $H_0: \theta = \theta_0$, альтернатива $H_1: \theta > \theta_0$. Построим по теореме Неймана-Пирсона наиболее мощный критерий при уровне значимости α . Рассмотрим систему множеств (делим и умножаем стандартные плотности):

$$K_t = \left\{ x : \exp \left(-\frac{1}{2} \sum_{j=1}^n (x_j - \theta)^2 + \frac{1}{2} \sum_{j=1}^n (x_j - \theta_0)^2 \right) \geq t \right\}$$

Данная система равносильна системе множеств (раскрываем квадраты и сокращаем):

$$\left\{ x : (\theta - \theta_0) \sum_{j=1}^n x_j \geq \tau \right\}$$

Так как $\theta > \theta_0$, получаем равносильное семейство

$$\{x : \bar{x}_n \geq c\}$$

Находим c :

$$\alpha = P_{\theta_0}(\bar{x}_n \geq c) = P_{\theta_0} \left(\frac{\sqrt{n}(\bar{x}_n - \theta_0)}{1} \geq \frac{\sqrt{n}(c - \theta_0)}{1} \right) = 1 - \Phi(\sqrt{n}(c - \theta_0))$$

То есть берем $c = \theta_0 + \frac{z_{1-\alpha}}{\sqrt{n}}$. Вычисляем мощность:

$$1 - \beta = P_{\theta}(\bar{x}_n \geq c) = 1 - \Phi(\sqrt{n}(c - \theta)) = 1 - \Phi(z_{1-\alpha} + \sqrt{n}(\theta_0 - \theta)) \xrightarrow{n \rightarrow \infty} 1$$

То есть мощность состоятельная.

При построении критерия, мы стремимся минимизировать ошибки первого и второго рода. Оценим снизу сумму вероятностей ошибок в случае простых гипотез (выбираем f_0 или f_1):

$$\alpha + \beta = P_0(X \in K) + P_1(X \notin K) = \int_K f_0(x) dx + \int_{\mathbb{R}^n \setminus K} f_1(x) dx = 1 + \int_K (f_0(x) - f_1(x)) dx$$

Если теперь $S = \{x : f_0(x) < f_1(x)\}$, то (если все с минусом попереносить, то получим $1 = 1$)

$$\int_S (f_0(x) - f_1(x)) dx = \int_{\mathbb{R}^n \setminus S} (f_1(x) - f_0(x)) dx = -\frac{1}{2} \int_{\mathbb{R}^n} |f_0(x) - f_1(x)| dx$$

Значит, (оставляем все, что идет с минусом)

$$\alpha + \beta \geq 1 + \int_{K \cap S} (f_0(x) - f_1(x)) dx \geq 1 + \int_S (f_0(x) - f_1(x)) dx = 1 - \frac{1}{2} \int_{\mathbb{R}^n} |f_0(x) - f_1(x)| dx$$

Таким образом, если плотности похожи друг на друга, то сумма вероятностей ошибки примерно равна 1, то есть не получится одновременно уменьшить вероятности обеих ошибок. Если же плотности сильно различаются, то сумма вероятностей примерно равна нулю, что естественно. Обычно добиться сильного различия плотностей можно лишь увеличением объема выборки.

15 χ^2 -критерий Пирсона

Пусть $X = (X_1, \dots, X_n)$ — выборка из дискретного распределения, при котором случайная величина принимает значения a_1, \dots, a_k с вероятностями p_1, \dots, p_k . Пусть основная гипотеза H_0 заключается в том, что $p_i = p_{i_0} \forall i \in \{1, \dots, k\}$. А альтернативная гипотеза H_1 заключается в том, что распределения вероятностей отлично от $\{p_{1_0}, \dots, p_{k_0}\}$. Пусть ν_i — количество a_i в X .

Теорема 16. При выполнении гипотезы H_0 случайная величина $\bar{\chi}^2 = \sum_{i=1}^k \left(\frac{\nu_i - np_{i_0}}{\sqrt{np_{i_0}}} \right)^2$ сходится по распределению к χ_{k-1}^2 .

Доказательство. Заметим, что $\nu_i = \sum_{j=1}^n \text{Ind}_{X_j=a_i}$. Рассмотрим случайный вектор

$\left(\frac{\nu_1 - np_{1_0}}{\sqrt{np_{1_0}}}, \dots, \frac{\nu_k - np_{k_0}}{\sqrt{np_{k_0}}} \right)$. По многомерной ЦПТ (теорема 8) данный вектор сходится по распределению к многомерному нормальному вектору $Z = (Z_1, \dots, Z_k)$ с нулевым вектором средних и матрицей ковариации $R = (r_{ij})$, где

$$r_{ii} = \text{cov} \left(\frac{\text{Ind}_{X_1=a_i}}{\sqrt{p_{i_0}}}, \frac{\text{Ind}_{X_1=a_i}}{\sqrt{p_{i_0}}} \right) = \mathbb{D} \frac{\text{Ind}_{X_1=a_i}}{\sqrt{p_{i_0}}} = \frac{p_{i_0}(1 - p_{i_0})}{p_{i_0}} = 1 - p_{i_0}$$

$$r_{ij} = \text{cov} \left(\frac{\text{Ind}_{X_1=a_i}}{\sqrt{p_{i_0}}}, \frac{\text{Ind}_{X_1=a_j}}{\sqrt{p_{j_0}}} \right) = \frac{1}{\sqrt{p_{i_0}p_{j_0}}} (\mathbb{E} [\text{Ind}_{X_1=a_i} \text{Ind}_{X_1=a_j}] - p_{i_0}p_{j_0}) = \frac{1}{\sqrt{p_{i_0}p_{j_0}}} (0 - p_{i_0}p_{j_0}) = -\sqrt{p_{i_0}p_{j_0}}$$

По теореме о наследовании сходимости (предложение 5) случайные величины $\bar{\chi}^2$ сходятся по распределению к $|Z|^2 = Z_1^2 + \dots + Z_k^2$. Покажем, что $|Z|^2 \sim \chi_{k-1}^2$. Заметим, что верно равенство

$$R = E - (\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}})^T (\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}})$$

Рассмотрим ортогональную матрицу, у которой первая строка имеет вид $(\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}})$. Тогда ковариационная матрица случайного вектора $V = CZ$ имеет вид:

$$CRC^T = E - C(\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}})^T (\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}}) C^T = E - e_{11}$$

где e_{11} — матрица, где 1 стоит в первой ячейки, а все остальное нули (так получается, потому что в $(\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}}) C^T$ при умножении на первый столбец мы получаем 1, так как просуммировали вероятности, а дальше мы вектор умножаем на столбцы, ортогональные ему, получаем e_{11} , аналогично в $C(\sqrt{p_{1_0}}, \dots, \sqrt{p_{k_0}})^T$). Следовательно $v_1 \equiv 0$ (так как нулевая дисперсия). Так как мы умножили на ортогональную матрицу, то длина вектора сохранилась, отсюда по определению χ_{k-1}^2 получаем

$$|Z|^2 = |V|^2 = v_2^2 + \dots + v_k^2 \sim \chi_{k-1}^2$$

■

Отсюда можем сформулировать следующий критерий уровня значимости α : пусть x_α выбрано так, что $P(\chi_{k-1}^2 \geq x_\alpha) = \alpha$. Тогда по доказанному, в случае справедливости гипотезы H_0

$$P \left(\sum_{i=1}^k \left(\frac{\nu_i - np_{i_0}}{\sqrt{np_{i_0}}} \right)^2 \geq x_\alpha \right) \xrightarrow{n \rightarrow \infty} \alpha$$

Если на конкретной реализации выборки мы получаем

$$\sum_{i=1}^k \left(\frac{\nu_i - np_{i_0}}{\sqrt{np_{i_0}}} \right)^2 < x_\alpha,$$

то H_0 принимается, иначе отклоняется.

16 Эмпирическая функция распределения и теорема Гливленко-Кантелли

Пусть $X = (X_1, \dots, X_n)$ — выборка из распределения с функцией распределения F . Рассмотрим на \mathbb{R} равномерное вероятностное распределение, расположенное в точка X_1, \dots, X_n , то есть $P^*(B) = \frac{\#\{X_j \in B\}}{n}$. Построена последовательность эмпирических распределений. Для эмпирических распределений справедлива следующая теорема.

Теорема 17. Для произвольного множества $B \in \mathcal{B}(\mathbb{R})$, $P_n^*(B) \xrightarrow{n.n.} P(X_1 \in B)$ (то есть эмпирическая вероятность стремится к реальной)

Доказательство. Заметим, что $P^*(B) = \frac{1}{n} \sum_{j=1}^n \text{Ind}_{X_j \in B}$. По УЗБЧ: $P^*(B) \rightarrow \mathbb{E} \text{Ind}_{X_1 \in B} = P(X_1 \in B)$

■

Определение 18. Случайную величину

$$F_n^*(t) = \frac{1}{n} \sum_{j=1}^n \text{Ind}_{X_j \in (-\infty, t]}$$

называют *эмпирической функцией распределения*. Так как

$$\mathbb{E} F_n^*(t) = \frac{1}{n} \sum_{j=1}^n P(X_j \leq t) = P(X_1 \leq t) = F(t),$$

то F_n^* является несмещенной оценкой функции распределения F .

Теорема 18. (Теорема Гливленко-Кантелли)

Величина $\sup_{t \in \mathbb{R}} |F_n^*(t) - F(t)| \xrightarrow{n.n.} 0$ (то есть имеет место равномерная сходимость)

Доказательство. Доказательство проведем только для непрерывной F . Зафиксируем $N \in \mathbb{N}$. Пусть точки t_0, \dots, t_N выбраны так, что $F(t_0) = 0$, $F(t_1) = \frac{1}{N}$, \dots , $F(t_N) = 1$, в частности $t_0 = -\infty$, $t_N = +\infty$. Тогда при $t \in [t_k, t_{k+1})$ выполнено

$$F_n^*(t) - F(t) \leq F_n^*(t_{k+1}) - F(t_k) = F_n^*(t_{k+1}) - F(t_{k+1}) + \frac{1}{N}$$

$$F_n^*(t) - F(t) \geq F_n^*(t_k) - F(t_{k+1}) = F_n^*(t_k) - F(t_k) - \frac{1}{N}$$

То есть знаем, что

$$|F_n^*(t) - F(t)| \leq \sup_k |F_n^*(t_k) - F(t_k)| + \frac{1}{N}$$

Теперь заметим, что для каждой точки t_k по УЗБЧ (аналогично предыдущей теореме) $F_n^*(t_k) \xrightarrow{n.n.} F(t_k)$. Введем событие $A_k = \left\{ F_n^*(t_k) \xrightarrow{n.n.} F(t_k) \right\}$, ясно, что $P(A_k) = 1$ для $k \in \{1, \dots, N-1\}$.

Рассмотрим событие $A = \bigcap_{k=1}^{N-1} A_k$, тогда справедливо равенство $\bar{A} = \bigcup_{k=1}^{N-1} \bar{A}_k$. Очевидно, что

$P(\bar{A}) \leq \sum_{k=1}^{N-1} P(\bar{A}_k) = 0$, следовательно $P(\bar{A}) = 0$, а $P(A) = 1$. Грубо говоря, на множестве исходов из A (которое по сути почти все множество исходов) имеем (для любого $\varepsilon > 0$, начиная с некоторого N_0)

$$\sup_{t \in \mathbb{R}} |F_n^*(t) - F(t)| \leq \sup_k |F_n^*(t_k) - F(t_k)| + \frac{1}{N} \leq \varepsilon + \frac{1}{N}$$

Теперь $N \rightarrow \infty$ и получаем

$$\lim_{n \rightarrow \infty} \sup_{t \in \mathbb{R}} |F_n^*(t) - F(t)| = 0$$

с вероятностью $P(A) = 1$, то есть почти наверное. ■

Обычно для построения эмпирической функции распределения используют следующую процедуру. Элементы выборки упорядочивают по возрастанию: $X_{(1)}, \dots, X_{(n)}$. Тогда $F_n^*(t) = \frac{k}{n}$ при $t \in [X_{(k)}, X_{(k+1)})$